Hojas de Trabajo, Restricciones, Visión de Arquitectura, ASRs, Detalle Arquitectura y Diseño de Expirimento

Solventa: construyendo la aseguradora digital de las finanzas abiertas

MISW4501 · Proyecto Final

Maestría en Ingeniería de Software · Universidad de los Andes

Equipo de Arquitectura · Grupo 6

Versión 4.1

Control de versiones del documento

Versión	Momento	Contenido incorporado
1.0	Agosto de 2026	Problema de negocio, objetivos, restricciones de negocio y de tecnología, atributos de calidad, catorce escenarios de calidad y backlog de catorce ASR. Modelos VC-001 a VC-004 en versión 1.0.
2.0	Agosto de 2026	Hoja de trabajo de diseño de experimentos. Se definen el Experimento 1 sobre ASR-07 y el Experimento 2 sobre ASR-06, con hipótesis, punto de sensibilidad, estilos, tácticas, patrones, componentes, conectores y esfuerzo.
3.0	Septiembre de 2026	Diseño detallado de patrones y tácticas sobre las tres vistas (sección 9.5). Entran al modelo funcional el Monitor de Salud y Retiro, el Validador de Consenso, el Circuit Breaker Global, los Workers de Absorción de Picos y las Réplicas Síncronas Multi-AZ.
4.0	20 de septiembre de 2026	Se suman el bloque de datos de la vista de información (secciones 9.2.1 a 9.2.4) y el plan de trabajo por sprint (sección 12).Ejecución y resultados medidos de los dos experimentos (sección 10). Los modelos VC-003 y VC-004 pasan a versión 2.0 con los cambios que la medición dejó validados. Nueva sección 11 con el registro ordenado de la evolución de la arquitectura.
4.1	26 de septiembre de 2026	La sección 13 documenta el prototipo navegable, en el portal web y en la aplicación móvil, y deja de describir la implementación del sistema. El índice incorpora las secciones 11 a 14 con los títulos vigentes.

Contenido

1. Problema de negocio a resolver **3**
1.1 Tensión entre atributos de calidad 3
2. Objetivos de negocio **4**
3. Restricciones de negocio **6**
3.1 Requisitos de cumplimiento 7
4. Restricciones de tecnología **9**
4.1 Requisitos del sistema 10
5. Requisitos de calidad **12**
5.1 Atributos de calidad 12
5.2 Especificación de escenarios de calidad 12
6. Backlog de arquitectura **16**
7. Riesgos identificados **22**
8. Esfuerzo estimado para construir la aplicación **23**
9. Modelos de arquitectura **24**
9.1 Modelo de contexto 24
9.2 Vista de información 26
9.3 Vista funcional 32
9.4 Vista de despliegue 34
9.5 Diseño detallado de arquitectura 36
10. Experimentos **40**
10.1 Experimento 1 — Continuidad de la cotización ante la caída de una instancia 40
10.2 Experimento 2 — Absorción de una avalancha de eventos paramétricos con cola de eventos y workers 45
11. Evolución de la arquitectura **52**
11.1 Registro ordenado de mejoras 52
11.2 Cambios validados en el modelo de componentes (VC-003 2.0) 53
11.3 Cambios validados en el modelo de despliegue (VC-004 2.0) 54
12. Plan de trabajo **54**
12.1 Resumen por sprint 55
12.2 Distribución de carga por responsable 55
12.3 Sprint 1 55
12.4 Sprint 2 55
12.5 Sprint 3 56
13. Documentación técnica del prototipo **58**
13.1 Organización del prototipo 58
13.2 Datos del prototipo 58
13.3 Comportamiento simulado en web y en móvil 58
13.4 Cómo abrir el prototipo 59
14. Guía de usuario **59**
14.1 Canales y recorridos disponibles 59
14.2 Portal Web: cotización y gestión de pólizas 60
14.3 Portal Web: socios e integraciones 60
14.4 Aplicación Mobile: reporte de siniestro y asistencia 61
14.5 Aplicación Mobile: compra y activación de un seguro 62
14.6 Aplicación Mobile: renovación de pólizas 63
14.7 Validaciones y estados que debe revisar el usuario 64

1. Problema de negocio a resolver

El mercado asegurador en América Latina sigue con baja penetración, emisión en días y una operación que todavía depende de trabajo manual. Como cada póliza nueva exige ese trabajo, el costo unitario no baja cuando crece el volumen. Solventa se constituye en 2026 como aseguradora digital, sin sistemas previos que conservar, y opera sobre una plataforma construida en la nube.

La venta embebida choca con ese modelo. El seguro suele pedirse fuera del flujo en el que el cliente ya está comprando: un tiquete, un arriendo de vehículo o un crédito. Si lo sacan a un trámite aparte, la cobertura se abandona y es difícil recuperarla. En vida hipotecario el problema es otro: el precio se arma por edad y monto, el buen riesgo paga lo mismo que el malo y se lleva el negocio quien cobre menos. Ese ramo es grande y está atado a la originación del crédito, de modo que perfilar en línea, dentro del mismo flujo, no es un adorno comercial: es la condición para competir.

El siniestro es donde se pierde al cliente que ya compró. Los soportes llegan por canales manuales, la evaluación tarda días y el asegurado no ve el estado de su solicitud. Esa demora se nota en la renovación: la confianza se rompe cuando el seguro debería cumplirse.

Cada socio que exige una integración hecha a su medida encarece el alta y pone techo a la meta de más de 30 socios y 5 millones de pólizas activas en 36 meses. Open Finance, Open Data, KYC/AML y las pasarelas de pago no ofrecen latencia ni disponibilidad estables: si uno de esos terceros se degrada, el cliente deja la compra en el canal del aliado. El Decreto 1297 de 2022 y la Circular Externa 004 de 2024 de la Superintendencia Financiera condicionan, además, el uso de datos financieros del consumidor a un consentimiento verificable y a decisiones de suscripción que se puedan explicar. Esa traza no se reconstruye con un proceso manual.

Hace falta una plataforma en la nube, construida desde cero, que cotice, suscriba, emita y pague siniestros tanto en el canal del socio como en los clientes web y móvil de Solventa. Las dependencias externas hay que absorberlas sin incumplir el tiempo de respuesta ni la continuidad del servicio. El resto del documento elige esa arquitectura y la confronta con latencia, escalabilidad, disponibilidad, facilidad de modificación y facilidad de integración.

1.1 Tensión entre atributos de calidad

Los atributos de calidad del caso no se maximizan a la vez. Cada decisión mejora uno y recorta otro. Las dos tensiones que más empujan el diseño son estas:

- Si se parten más componentes, actuaría puede cambiar reglas de rating sin tocar el resto del sistema; cada hop extra, sin embargo, se come el presupuesto de latencia de la cotización embebida.
- Replicar en más de una región sostiene el RTO de cinco minutos, pero una escritura deja de ser un round-trip local y eso choca con el mismo presupuesto de milisegundos.

Prioridad	Atributos	Razón
A demostrar primero	Latencia y facilidad de integración	Sin precio en el canal del socio no hay venta embebida. Sin un alta de aliado en el orden de una semana no se llega a 30 socios. El primer experimento cubre el flujo de cotización; el segundo, el onboarding de un socio de prueba.
Piso de operación	Disponibilidad	Compra y siniestros tienen que seguir disponibles de noche y en festivos. La regulación de finanzas abiertas, además, exige un mínimo de protección y de traza del dato; no es un atributo que se pueda posponer.
Quedan en el diseño	Escalabilidad y facilidad de modificación	El particionamiento por capacidad y el escalamiento horizontal se deciden ahora. La evidencia de carga y de resiliencia llega después, cuando haya un sistema que cargar.

2. Objetivos de negocio

Objetivo 1: Emitir en segundos lo que hoy toma días

Descripción del objetivo	El CEO y Operaciones necesitan que una póliza que hoy se emite en días quede emitida en segundos. Si no, el costo por póliza sigue atado al número de personas que intervienen en cada emisión.
Tiempo de cumplimiento	Primeros 12 meses de operación
Mejora esperada al negocio	El costo unitario deja de crecer con el volumen. El equipo de operaciones se concentra en la venta asistida y en los casos que sí requieren juicio.
Cómo considera que pueda afectar la arquitectura del sistema este objetivo	Facilidad de modificación. Las reglas de suscripción y de puntuación deben vivir en componentes independientes que puedan cambiar sin redesplegar el sistema completo

Objetivo 2: Vender dentro del canal del socio, en el momento de la necesidad

Descripción del objetivo	Producto y mercadeo necesitan que la cotización y la compra ocurran sin sacar al cliente del canal donde apareció la necesidad. El precio tiene que estar en pantalla mientras esa persona compra el tiquete, arrienda el carro o toma el crédito.
Tiempo de cumplimiento	Primeros 12 meses de operación
Mejora esperada al negocio	Se recuperan las ventas que hoy se caen al mandar al cliente a un flujo aparte. El aliado puede ofrecer la cobertura sin armar un backoffice propio.
Cómo considera que pueda afectar la arquitectura del sistema este objetivo	Latencia. El precio debe llegar antes de que el cliente abandone la pantalla del socio, y ese cálculo depende de terceros con tiempos de respuesta impredecibles

Objetivo 3: Liquidar siniestros de bajo monto sin un trámite de días

Descripción del objetivo	Operaciones y siniestros necesitan pagar los avisos de bajo monto y los paramétricos en minutos, sin expediente, y dejar al asegurado al tanto del estado de su solicitud.
Tiempo de cumplimiento	Primeros 18 meses de operación
Mejora esperada al negocio	Mejora la renovación porque el cliente vio el pago. También baja el costo de atender siniestros pequeños, que hoy recorren el mismo trámite que uno grande.
Cómo considera que pueda afectar la arquitectura del sistema este objetivo	Disponibilidad. El canal de siniestros responde 24/7, y la caída de un módulo no crítico debe dejar en pie el aviso y el pago

Objetivo 4: Crecer la red de distribución a 30+ socios

Descripción del objetivo	La Junta y alianzas fijan como meta 5 millones de pólizas activas y más de 30 socios de distribución conectados. El volumen entra por canales que Solventa no opera.
Tiempo de cumplimiento	36 meses
Mejora esperada al negocio	El crecimiento no depende de una fuerza de ventas propia. El costo marginal por socio debería bajar a medida que la red se repite sobre el mismo contrato de integración.

Cómo considera que pueda afectar la arquitectura del sistema este objetivo	Escalabilidad y facilidad de integración. Un socio en campaña multiplica su tráfico por 100, y ese pico se absorbe sin afectar a los demás aliados

3. Restricciones de negocio

Una restricción de negocio es una condición que el negocio o el proyecto ya impusieron y que reduce el espacio de diseño: plazo, equipo, presupuesto, alcance y modelo comercial.

Las normas, circulares y estándares de industria no entran en esta lista. No las decide el negocio: las exige el regulador o el sector, y se tratan como requisitos de cumplimiento en la sección 3.1.

RN-01: Partida en verde, sin sistemas heredados

Descripción de la restricción	No hay sistemas legados que deban conservarse ni integrarse. El equipo diseña y construye desde cero
Usuario que expresa esta restricción	CEO y CTO de Solventa
Justificación para esta restricción	La empresa se constituye en 2026 como aseguradora digital. No hay un core previo que preservar ni un lote de integraciones heredadas que condicionen el estilo.
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Libera la elección de estilo y de persistencia, pero obliga a justificar cada frontera: no hay un sistema previo que ancle las decisiones

RN-02: Equipo reducido con un sistema que debe crecer

Descripción de la restricción	El equipo es reducido y el sistema debe poder crecer; la complejidad organizacional aumenta con el negocio
Usuario que expresa esta restricción	CTO y equipos de desarrollo
Justificación para esta restricción	La carga cognitiva y la velocidad de despliegue son el interés arquitectónico de desarrollo y SRE
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Facilidad de modificación. Las partes del sistema deben poder cambiarse y desplegarse sin que operar varias a la vez rebase la capacidad del equipo

RN-03: Tiempo de diseño y construcción

Descripción de la restricción	Hay un máximo de 4 meses para diseñar la arquitectura, construir los clientes web y móvil y ejecutar los experimentos que la validan
Usuario que expresa esta restricción	CEO y Junta Directiva de Solventa
Justificación para esta restricción	El time-to-market es el interés declarado de la Junta: la ventana del seguro embebido y de las finanzas abiertas está abierta ahora
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Acota el diseño a un estilo que el equipo pueda construir, desplegar y evaluar con evidencia dentro del plazo

RN-04: Costo de la nube previsible

Descripción de la restricción	El costo total de propiedad y el gasto de nube deben ser eficientes y previsibles
Usuario que expresa esta restricción	CFO, con el CTO como responsable del control del costo de la nube

Justificación para esta restricción	La previsibilidad del gasto y el costo unitario son intereses declarados de Finanzas y de la Junta
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Escalabilidad. Empuja a escalar solo las partes que lo justifican, en lugar de crecer el sistema completo ante cada pico

RN-05: Alcance de mercado y ramos iniciales

Descripción de la restricción	La operación arranca en Colombia con seis ramos: viaje, protección de dispositivos, microseguros de vida, paramétrico, protección de pagos ligada a crédito y vida hipotecario. La expansión a México, Chile y Perú entra dentro de los 36 meses
Usuario que expresa esta restricción	Junta Directiva y área de Producto
Justificación para esta restricción	Concentra la inversión en el mercado donde el marco de finanzas abiertas ya está habilitado
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Facilidad de modificación. Un ramo o un país nuevo debe resolverse por configuración del catálogo y por componentes acotados

RN-06: Distribución embebida y dependencia de terceros

Descripción de la restricción	El volumen entra por canales de socios que Solventa no controla, y gran parte del valor depende de integraciones externas (Open Finance, Open Data, KYC/AML, pagos, reaseguro) fuera de su control
Usuario que expresa esta restricción	Junta Directiva, equipo de alianzas y CTO
Justificación para esta restricción	La meta de 5 millones de pólizas y 30+ socios se sostiene en el canal ajeno y en datos y servicios de terceros
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Facilidad de integración y disponibilidad. El contrato de API es el producto; cada socio se aísla; cada tercero se consume detrás de un adaptador que tolera falla y latencia impredecible

3.1 Requisitos de cumplimiento

Estos requisitos no los fija el negocio: los imponen la ley, el supervisor y los estándares del sector. Solventa opera bajo habeas data, finanzas abiertas y PCI-DSS, y trata la seguridad y la privacidad como requisitos de diseño, no como controles añadidos al final.

Se verifican con evidencia propia (consentimiento, linaje, auditoría, ámbito PCI). No acotan una tecnología de antemano ni son restricciones de negocio.

ID	Norma o estándar	Qué exige	Cómo lo cubre la arquitectura
RC-01	Ley 1581 de 2012, habeas data	Tratamiento, finalidad y autorización del dato personal, con derecho de acceso, corrección y supresión.	Consentimiento como entidad propia, con alcance, fuente y fecha de revocación, y borrado trazable.
RC-02	Decreto 1297 de 2022 y Circular Externa 004 de	Intercambio de datos financieros del consumidor con consentimiento	Revocación efectiva en 5 minutos propagada a todos los consumidores, y

ID	Norma o estándar	Qué exige	Cómo lo cubre la arquitectura
	2024 de la SFC, finanzas abiertas	verificable y revocable, y decisiones explicables.	linaje de cada señal externa usada en el precio.
RC-03	PCI-DSS en el flujo de pagos	Protección del dato de medio de pago en tránsito, en reposo y en el procesamiento.	Ámbito PCI acotado al servicio de pagos, con tokenización de PII y cifrado gestionado por AWS KMS.
RC-04	Explicabilidad de la suscripción ante la SFC y actuaría	Reconstrucción de cualquier decisión de suscripción y del precio que la acompañó.	Registro de auditoría con las reglas aplicadas, la versión del modelo, las fuentes consultadas y sus valores.
RC-05	Regulación de finanzas abiertas en maduración	Absorber los cambios de Finanzas Abiertas y habeas data que lleguen durante la operación, con impacto trazable y acotado.	Los controles viven en Consentimiento, Auditoría y los adaptadores. Un cambio normativo no atraviesa el núcleo.

4. Restricciones de tecnología

Una restricción de tecnología es una decisión ya tomada que el equipo no puede revertir: plataforma de cómputo, herramientas y tope de infraestructura. Solventa nace nativa en la nube; el resto de esta lista son límites del proyecto.

No son restricciones de tecnología las capacidades que el sistema debe ofrecer (canales web y móvil, recorridos, integraciones, contratos de API, resiliencia ante terceros). Eso describe lo que la solución hace, y se documenta como requisitos del sistema en la sección 4.1. La elasticidad, las zonas y el RTO/RPO se miden en los escenarios de disponibilidad (sección 5), no se listan aquí.

RT-01: Nube primero

Descripción de la restricción	La solución se construye sobre nube pública. No hay data center propio ni operación on-premise
Usuario que expresa esta restricción	CTO y equipo de arquitectura
Justificación para esta restricción	Una aseguradora nativa digital opera con infraestructura elástica, multi-zona y con posibilidad multi-región
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Descarta un diseño on-premise o híbrido con legado. Las tácticas de disponibilidad (zonas, regiones, replicación) se eligen dentro del modelo de nube

RT-02: Integraciones externas contra simuladores

Descripción de la restricción	Open Finance, Open Data, KYC/AML, pasarelas de pago y reaseguro se consumen contra simuladores y entornos sandbox durante el proyecto
Usuario que expresa esta restricción	Gerente del proyecto y equipo de arquitectura
Justificación para esta restricción	Los proveedores reales operan bajo contratos y tiempos ajenos al equipo; esas dependencias están fuera del control de Solventa
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Facilidad de integración. Cada tercero entra detrás de un adaptador con interfaz estable; el simulador reproduce latencia y fallas sin acoplar el núcleo a un proveedor concreto

RT-03: Herramientas open source, sin licencias de pago

Descripción de la restricción	El stack de construcción y de pruebas se limita a herramientas open source: pytest, Vitest, Jest, Playwright y JMeter
Usuario que expresa esta restricción	CFO y gerente del proyecto
Justificación para esta restricción	El presupuesto del proyecto excluye licencias de software y granjas de dispositivos de terceros
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Acota las tecnologías elegibles y el diseño de los experimentos de arquitectura

RT-04: Infraestructura de pruebas sobre capa gratuita

Descripción de la restricción	Los ambientes de prueba en la nube operan sobre capa gratuita o créditos académicos de AWS

Usuario que expresa esta restricción	Gerente del proyecto
Justificación para esta restricción	El proyecto opera sin presupuesto de infraestructura propio
Cómo considera que pueda afectar la arquitectura del sistema esta restricción	Escalabilidad. La medición se ejecuta a escala reducida y el resultado se extrapola con capacity planning para dimensionar producción

4.1 Requisitos del sistema

Estos requisitos describen lo que la plataforma debe hacer. No fijan un lenguaje, un producto o un proveedor: fijan capacidades y contratos que cualquier diseño elegido debe satisfacer.

ID	Requisito	Origen	Cómo afecta la arquitectura
RS-01	El producto se ofrece en dos clientes con propósito distinto: web para la gestión completa y móvil para el autoservicio en movilidad.	Producto y crecimiento	Facilidad de integración. Obliga a decidir entre API única y backend por experiencia, y a versionar sin romper clientes ya desplegados.
RS-02	El cliente web cubre venta asistida, ciclo de vida de pólizas, back-office de socios y tableros de operación.	Operaciones, asesores y socios	El backend de experiencia web concentra la superficie funcional completa sin filtrar capacidades del dispositivo.
RS-03	El cliente móvil soporta reporte de siniestro con cámara y geoetiquetado, onboarding y autenticación biométrica, notificaciones push, geolocalización de prestadores, escaneo de documentos y billetera de pólizas con modo offline y sincronización posterior.	Cliente asegurado en movilidad	Facilidad de modificación e integración. Esas capacidades viven en el cliente y en su backend; no se replican como equivalente pleno en web.
RS-04	La plataforma cubre de extremo a extremo seis recorridos: cotización embebida, suscripción y emisión, siniestro asistido, siniestro paramétrico automático, perfilamiento y oferta de vida hipotecario, y gestión del ciclo de vida (renovación, cambio, cancelación y reporte).	Recorridos críticos del negocio	Las fronteras internas se alinean con esas capacidades de negocio para que un cambio de recorrido no atraviese el sistema.
RS-05	El sistema se conecta a Open Finance, Open Data, KYC/AML e identidad, pasarelas de pago y recaudo, firma electrónica, telemetría o IoT cuando aplique, socios embebidos y reaseguradoras.	Ecosistema de distribución y datos	Facilidad de integración. Cada dependencia externa se aísla detrás de un adaptador; el núcleo

ID	Requisito	Origen	Cómo afecta la arquitectura
			no habla el protocolo del tercero.
RS-06	El intercambio de cartera y siniestralidad con reaseguradoras se realiza sobre el estándar ACORD.	Reaseguradoras y actuaría	Un adaptador hace el mapeo semántico y el versionado de esquemas, de modo que el modelo interno no se acopla al estándar externo.
RS-07	Toda llamada a un tercero aplica timeout, reintento con backoff, circuit breaker, caché y operación degradada. Esos controles forman parte del contrato de calidad, no son opcionales.	Latencia y disponibilidad ante terceros	El presupuesto de cada journey se protege cuando el tercero se degrada o cae.
RS-08	Los datos personales y financieros se cifran en tránsito y en reposo, con tokenización de PII.	CISO y cumplimiento (RC-01, RC-03)	Seguridad. Implementa en el sistema lo que RC-01 y RC-03 exigen. El ámbito PCI se acota al servicio de pagos.
RS-09	La API se publica versionada, de modo que una versión nueva conviva con las que clientes y socios ya tienen desplegadas.	Clientes web, móvil y socios	Facilidad de integración. Un cambio no obliga a redesplegar web, móvil y socios al mismo tiempo.
RS-10	El sistema expone eventos de negocio a consumidores analíticos y de fraude con contratos claros, sin acoplar a los productores.	Analítica, fraude y cumplimiento	Facilidad de modificación e integración. Un consumidor nuevo se suma al bus de eventos sin tocar a quien publica el hecho.

5. Requisitos de calidad

5.1 Atributos de calidad

Los cinco ejes del caso, con la situación del negocio en la que cada uno se vuelve decisivo.

Atributo de Calidad	En qué situación es importante este atributo de calidad
Latencia	Cotización embebida en el canal del socio, perfilamiento en línea del vida hipotecario dentro del flujo de originación del crédito, y consulta del estado de una póliza o de un siniestro. El precio y la decisión deben llegar antes de que el cliente abandone la pantalla
Escalabilidad	Campaña de un socio que multiplica el tráfico por 100, cierre de mes en la originación hipotecaria, y evento climático que dispara pólizas paramétricas de forma simultánea. La carga llega en picos, no de forma uniforme
Disponibilidad	Operación 24/7 de la venta y del canal de siniestros, flujos de dinero en recaudo e indemnizaciones, caída de una zona o de una región de nube, y degradación de un proveedor externo de datos
Facilidad de modificación	Lanzamiento de un ramo nuevo, ajuste de la fórmula de rating por parte de actuaría, cambio normativo de finanzas abiertas, y reemplazo de un proveedor de KYC o de pagos
Facilidad de integración	Alta de un socio embebido con contratos y credenciales estándar, conexión de una fuente nueva de Open Data u Open Finance, consumo de la misma plataforma por los clientes web y móvil, e intercambio con reaseguradoras bajo estándares del sector

5.2 Especificación de escenarios de calidad

Cada escenario declara una medida de respuesta comprobable y el ambiente en el que esa medida aplica. En disponibilidad el estímulo es un fallo (omisión, caída o pérdida de un componente), no el uso normal del sistema. RTO y RPO se declaran juntos cuando cuantifican la misma recuperación.

ID: EC001	**Latencia**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Sistema del socio de distribución (banco, aerolínea, e-commerce)	Solicitud de cotización embebida desde el canal del socio	Sistema. API Gateway y servicio de Cotización y Rating	Producción bajo carga alta, en horario pico
Respuesta		**Medida de la Respuesta**	
Prima calculada y devuelta al canal del socio dentro del presupuesto de latencia		p95 menor o igual a 400 ms extremo a extremo	

ID: EC002	**Latencia**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Sistema de originación de crédito del banco aliado	Se recibe el consentimiento del cliente y se dispara el perfilamiento con Open Data y Open Finance	Sistema. Servicio de Perfilamiento y Personalización con sus adaptadores externos	Producción, dentro del flujo de originación del crédito
Respuesta		**Medida de la Respuesta**	

Perfil de riesgo y precio personalizado del seguro de vida hipotecario	p95 menor o igual a 400 ms

ID: EC003	**Latencia**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Servicio de Cotización y Rating	Se consulta a un tercero de Open Finance, Open Data o KYC dentro del flujo de cotización	Sistema. Adaptador del proveedor externo	Producción en operación normal
Respuesta		**Medida de la Respuesta**	
El adaptador entrega el dato del tercero al servicio que lo solicitó		p95 menor o igual a 300 ms por dependencia externa	

ID: EC004	**Escalabilidad**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Socio de distribución en campaña comercial	El tráfico de cotización del socio crece 100 veces respecto de su línea base	Sistema. Servicio de Cotización y Rating	Producción con pico de campaña sostenido
Respuesta		**Medida de la Respuesta**	
El sistema atiende el pico de cotizaciones sin rechazar solicitudes y sin degradar la latencia ni el aislamiento de los demás socios		50.000 cotizaciones por minuto, conservando el p95 menor o igual a 400 ms extremo a extremo	

ID: EC005	**Escalabilidad**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Socio de distribución en campaña comercial	El tráfico de cotización pasa de 500 a 50.000 cotizaciones por minuto	Sistema. Mecanismo de autoescalado del servicio de Cotización y Rating	Producción durante el arranque del pico
Respuesta		**Medida de la Respuesta**	
El mecanismo de autoescalado agrega réplicas hasta cubrir la demanda de 500 a 50.000 cotizaciones por minuto		50.000 cotizaciones por minuto alcanzadas en menos de 60 segundos, conservando el p95 menor o igual a 400 ms	

ID: EC006	**Escalabilidad**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Proveedor externo de datos climáticos y de vuelos	Un evento climático dispara pólizas paramétricas de forma simultánea	Sistema. Bus de eventos y servicio de siniestro paramétrico	Producción durante un evento externo masivo
Respuesta		**Medida de la Respuesta**	

Los eventos se absorben con contrapresión y se procesan de forma idempotente, sin pérdida y sin degradar la cotización en línea	1.000.000 de eventos procesados en 10 minutos, con cero eventos perdidos

ID: EC007	**Disponibilidad**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Instancia de un servicio crítico de venta o de siniestros	La instancia deja de responder (caída u omisión)	Flujos críticos de venta y siniestros	Producción, operación normal 24/7
Respuesta		**Medida de la Respuesta**	
El sistema detecta la instancia fallida, la retira del balanceo y continúa atendiendo sin intervención manual		Disponibilidad mensual mayor o igual a 99,97% (a lo sumo 13 minutos de indisponibilidad al mes)	

ID: EC008	**Disponibilidad**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Infraestructura de nube	Una zona de disponibilidad deja de operar por completo	Servicios críticos de venta y siniestros, y sus almacenes de datos	Producción, operación normal
Respuesta		**Medida de la Respuesta**	
El tráfico conmuta a las zonas restantes y la réplica de datos asume el rol primario, sin intervención manual y sin perder transacciones confirmadas		RTO menor o igual a 10 minutos y RPO menor o igual a 30 segundos	

ID: EC009	**Disponibilidad**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Infraestructura de nube	Se pierde una región completa	Plataforma de venta, siniestros y pagos	Producción, operación normal
Respuesta		**Medida de la Respuesta**	
El sistema conmuta a la región secundaria y conserva las transacciones confirmadas		RTO menor o igual a 5 minutos, sin pérdida de transacciones confirmadas	

ID: EC010	**Disponibilidad**	**Versión**	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Proveedor externo de Open Finance o de Open Data	El proveedor deja de responder (caída u omisión)	Journey de venta (cotización y perfilamiento)	Producción, operación normal
Respuesta		**Medida de la Respuesta**	
El sistema detecta la omisión, abre el circuit breaker y continúa la venta con perfil en caché o valor por defecto		Disponibilidad del journey de venta mayor o igual a 99,9% mientras el tercero está caído	

ID: EC011	Facilidad de modificación	Versión	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Humano del área de Actuaría	Solicitud de ajuste de la fórmula de precio y de las reglas de suscripción	Sistema. Componente de Cotización y Rating	Operación en mantenimiento
Respuesta		**Medida de la Respuesta**	
La fórmula queda modificada y desplegada de forma aislada, sin redesplegar el resto del sistema		Menos de 40 horas/hombre	

ID: EC012	Facilidad de modificación	Versión	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Humano del área de Producto	Se lanza un ramo nuevo de seguro, por ejemplo, mascotas	Sistema. Catálogo de Productos, componente de Rating y componente de Suscripción	Operación en mantenimiento
Respuesta		**Medida de la Respuesta**	
El ramo queda disponible en el cliente web, en el móvil y en el canal embebido, sin tocar el núcleo		Menos de 2 semanas-equipo	

ID: EC013	Facilidad de integración	Versión	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Equipo de alianzas de Solventa junto con el integrador técnico del socio	Un retailer solicita vender seguros a través de su propio canal vía API	Sistema. Componente de Socios y Gobierno de API, y API Gateway	Operación normal, con la red de socios existente activa
Respuesta		**Medida de la Respuesta**	
El socio queda habilitado con contrato de API, credenciales, alcances y cuotas propias, sin cambios en el núcleo		Menos de 1 semana	

ID: EC014	Facilidad de integración	Versión	1.0
Fuente	**Estímulo**	**Artefacto**	**Ambiente**
Humano del equipo de datos	Se suma un agregador o una fuente pública nueva de Open Data	Sistema. Adaptador de fuentes externas del componente de Perfilamiento	Operación en mantenimiento
Respuesta		**Medida de la Respuesta**	
La fuente queda conectada detrás del adaptador estándar y disponible para el perfilamiento, sin afectar a los consumidores existentes		Menos de 40 horas/hombre	

6. Backlog de arquitectura

Catorce requisitos significativos de arquitectura, uno por escenario de calidad. Cada uno declara una sola medida de respuesta, alineada con el escenario que lo origina.

ASR-01: Latencia de la cotización embebida

Como socio de distribución conectado al canal embebido de Solventa, cuando envío una solicitud de cotización desde mi propia aplicación, dado que el cliente está en mitad de una compra y abandona si el precio tarda, quiero que la plataforma devuelva la prima con un p95 menor o igual a 400 ms extremo a extremo, esto debe cumplirse de forma sostenida en horario pico, para que la venta del seguro ocurra dentro del momento de la necesidad

Escenario de origen	EC001
Atributo	Latencia
Fuente	Sistema del socio de distribución (banco, aerolínea, e-commerce, fintech o retailer)
Estímulo	Solicitud de cotización embebida en horario pico, con dependencia de reglas de rating y de señales de Open Finance
Artefacto	API Gateway y servicio de Cotización y Rating, con sus adaptadores externos
Ambiente	Producción bajo carga alta, con socios activos de forma simultánea
Medida de respuesta	p95 menor o igual a 400 ms extremo a extremo
Respuesta	El sistema calcula la prima combinando reglas de rating y señales de Open Finance. Si una dependencia externa supera su presupuesto, el adaptador corta la llamada y responde con valor en caché o con el valor por defecto, conservando el presupuesto total del flujo

ASR-02: Latencia del perfilamiento en línea de vida hipotecario

Como banco aliado que origina un crédito de vivienda, cuando el cliente otorga su consentimiento de Open Finance dentro del flujo de originación, dado que la oferta del seguro debe aparecer en la misma pantalla del crédito, quiero que Solventa entregue el perfil de riesgo y el precio personalizado con un p95 menor o igual a 400 ms, esto debe cumplirse en cada originación, para que la oferta de vida hipotecario compita sin interrumpir el trámite del crédito

Escenario de origen	EC002
Atributo	Latencia
Fuente	Sistema de originación de crédito del banco aliado
Estímulo	Se recibe el consentimiento del cliente y se dispara el perfilamiento sobre Open Data y Open Finance
Artefacto	Servicio de Perfilamiento y Personalización, caché de perfil y adaptadores de fuentes externas
Ambiente	Producción, dentro del recorrido de originación del crédito
Medida de respuesta	p95 menor o igual a 400 ms
Respuesta	El servicio consulta las fuentes en paralelo, aplica el presupuesto por dependencia y compone el perfil con los datos que llegaron a tiempo, dejando registrado qué fuentes se usaron y cuáles se resolvieron desde caché

ASR-03: Presupuesto de latencia por dependencia externa

Como arquitecto de la plataforma, cuando el flujo de cotización consulta a un proveedor de Open Finance, Open Data o KYC, dado que el presupuesto total del flujo se reparte entre varias llamadas, quiero que cada dependencia externa se resuelva con un p95 menor o igual a 300 ms, esto debe cumplirse en cada llamada de operación normal, para que la suma de las dependencias quepa dentro del presupuesto del flujo

Escenario de origen	EC003
Atributo	Latencia
Fuente	Servicio de Cotización y Rating
Estímulo	Se consulta a un proveedor externo dentro del flujo de cotización
Artefacto	Adaptador del proveedor externo, con su caché y su circuit breaker
Ambiente	Producción en operación normal
Medida de respuesta	p95 menor o igual a 300 ms por dependencia externa
Respuesta	El adaptador aplica el timeout duro de 3000 ms, corta la llamada al superarlo y devuelve el valor en caché, dejando marcada la respuesta como degradada

ASR-04: Volumen de cotización en campaña de socio

Como equipo de alianzas de Solventa, cuando un socio lanza una promoción y su tráfico crece 100 veces, dado que la campaña se pierde si la plataforma rechaza solicitudes, quiero que el sistema procese 50.000 cotizaciones por minuto, esto debe sostenerse durante todo el pico de campaña, para aprovechar la campaña completa

Escenario de origen	EC004
Atributo	Escalabilidad
Fuente	Socio de distribución en campaña comercial
Estímulo	El tráfico de cotización del socio crece 100 veces respecto de su línea base
Artefacto	Servicio de Cotización y Rating y API Gateway con cuotas por socio
Ambiente	Producción con pico de campaña sostenido
Medida de respuesta	50.000 cotizaciones por minuto, conservando el p95 menor o igual a 400 ms extremo a extremo
Respuesta	El servicio de cotización opera con réplicas horizontales y las cuotas por socio contienen el pico dentro del aislamiento de ese aliado. El p95 de cotización se conserva en 400 ms y el resto de la red permanece estable

ASR-05: Tiempo de reacción del autoescalado

Como equipo de operación de la plataforma, cuando el tráfico de cotización pasa de 500 a 50.000 por minuto, dado que el pico llega sin aviso previo del socio, quiero que la capacidad quede ampliada en menos de 60 segundos, esto debe ocurrir en cada arranque de pico, para que la latencia se conserve durante la subida

Escenario de origen	EC005
Atributo	Escalabilidad
Fuente	Socio de distribución en campaña comercial

Estímulo	El tráfico de cotización pasa de 500 a 50.000 cotizaciones por minuto
Artefacto	Mecanismo de autoescalado del servicio de Cotización y Rating
Ambiente	Producción durante el arranque del pico
Medida de respuesta	50.000 cotizaciones por minuto alcanzadas en menos de 60 segundos, conservando el p95 menor o igual a 400 ms
Respuesta	El autoescalado detecta la subida por métricas de utilización y de cola, y agrega réplicas del servicio hasta cubrir de 500 a 50.000 cotizaciones por minuto sin romper el presupuesto de latencia

ASR-06: Absorción de un evento paramétrico masivo

Como equipo de operaciones y siniestros, cuando un evento climático dispara de forma simultánea las pólizas paramétricas de una región, dado que cada evento debe evaluarse y pagarse sin intervención humana, quiero que la plataforma procese 1.000.000 de eventos en 10 minutos, esto debe ocurrir cada vez que se active un evento externo, para que el pago automático llegue al asegurado en el momento en que lo necesita

Escenario de origen	EC006
Atributo	Escalabilidad
Fuente	Proveedor externo de datos climáticos y de estado de vuelos
Estímulo	Un evento externo cruza el umbral definido y dispara las pólizas paramétricas asociadas
Artefacto	Bus de eventos particionado y servicio de siniestro paramétrico
Ambiente	Producción durante un evento externo masivo
Medida de respuesta	1.000.000 de eventos procesados en 10 minutos, con cero eventos perdidos
Respuesta	El bus retiene los eventos y aplica contrapresión sobre los consumidores, que escalan de forma horizontal y procesan de manera idempotente. Cada póliza se liquida una sola vez y la cotización en línea no se degrada

ASR-07: Disponibilidad de los flujos críticos

Como cliente asegurado de Solventa, cuando compro un seguro o reporto un siniestro a cualquier hora, dado que la plataforma opera 24/7 y el siniestro no espera horario, quiero una disponibilidad mensual mayor o igual a 99,97% en los flujos críticos, esto debe medirse mes a mes, para que el canal esté en pie cuando lo necesite

Escenario de origen	EC007
Atributo	Disponibilidad
Fuente	Instancia de un servicio crítico de venta o de siniestros
Estímulo	La instancia deja de responder (caída u omisión)
Artefacto	Flujos críticos de venta y siniestros, con sus servicios y almacenes de datos
Ambiente	Producción, operación normal 24/7
Medida de respuesta	Disponibilidad mensual mayor o igual a 99,97% (a lo sumo 13 minutos de indisponibilidad al mes)

Respuesta	El monitor de salud retira la instancia del balanceador y el tráfico sigue en las réplicas sanas, sin interrumpir venta ni siniestros

ASR-08: Recuperación ante la caída de una zona

Como responsable de operación de la plataforma, cuando falla una zona de disponibilidad completa, dado que la venta y el aviso de siniestro siguen activos, quiero que el servicio quede restablecido con un RTO menor o igual a 10 minutos, esto debe cumplirse sin intervención manual, para que la caída de infraestructura deje de ser una interrupción del servicio

Escenario de origen	EC008
Atributo	Disponibilidad
Fuente	Infraestructura de nube
Estímulo	Una zona de disponibilidad deja de operar por completo
Artefacto	Servicios críticos de venta y siniestros, y sus almacenes de datos
Ambiente	Producción, operación normal
Medida de respuesta	RTO menor o igual a 10 minutos y RPO menor o igual a 30 segundos
Respuesta	El balanceador retira la zona afectada, el tráfico se atiende en las zonas restantes y la réplica síncrona asume el rol primario conservando las transacciones confirmadas

ASR-09: Failover ante la caída de una región

Como responsable de la información de Solventa, cuando falla una zona de disponibilidad completa, dado que hay transacciones de dinero confirmadas en curso, quiero un RPO menor o igual a 30 segundos, esto debe cumplirse en cada conmutación, para que ninguna transacción confirmada se pierda

Escenario de origen	EC009
Atributo	Disponibilidad
Fuente	Infraestructura de nube
Estímulo	Se pierde una región completa
Artefacto	Plataforma de venta, siniestros y pagos
Ambiente	Producción, operación normal
Medida de respuesta	RTO menor o igual a 5 minutos, sin pérdida de transacciones confirmadas
Respuesta	El failover multi-región promociona la región secundaria. Las transacciones confirmadas ya replicadas se conservan y los pagos idempotentes no se duplican

ASR-10: Continuidad ante la degradación de un proveedor externo

Como cliente que está comprando un seguro, cuando el proveedor de Open Finance supera los 3000 ms o deja de responder, dado que Solventa depende de terceros que están fuera de su control, quiero una disponibilidad del flujo de venta mayor o igual a 99,9%, esto debe cumplirse cada vez que un tercero se degrade, para que la falla de un proveedor deje de traducirse en una venta perdida

Escenario de origen	EC010

Atributo	Disponibilidad
Fuente	Proveedor externo de Open Finance o de Open Data
Estímulo	El proveedor deja de responder (caída u omisión)
Artefacto	Adaptador del tercero, caché de perfil y servicio de Cotización y Rating
Ambiente	Producción, operación normal
Medida de respuesta	Disponibilidad del journey de venta mayor o igual a 99,9% mientras el tercero está caído
Respuesta	El circuit breaker abre el circuito hacia el proveedor caído. El sistema resuelve con el perfil en caché o con el valor por defecto y marca la cotización como calculada en modo degradado, para que actuaría pueda reconstruir la decisión

ASR-11: Cambio aislado en las reglas de rating

Como analista de actuaría, cuando ajusto la fórmula de precio o las reglas de suscripción, dado que el mercado y la siniestralidad cambian de forma continua, quiero resolver el cambio en menos de 40 horas/hombre, esto debe cumplirse en cada ajuste, para mover el precio al ritmo que exige el negocio

Escenario de origen	EC011
Atributo	Facilidad de modificación
Fuente	Área de Actuaría
Estímulo	Solicitud de ajuste de la fórmula de precio y de las reglas de suscripción
Artefacto	Componente de Cotización y Rating
Ambiente	Operación en mantenimiento
Medida de respuesta	Menos de 40 horas/hombre
Respuesta	El componente de rating expone las reglas como configuración versionada, de modo que el cambio se despliega de forma independiente y queda registrado con su versión para efectos de auditoría

ASR-12: Lanzamiento de un ramo nuevo sin tocar el núcleo

Como líder de producto, cuando lanzo una línea nueva de seguro como mascotas, dado que la meta de crecimiento depende de experimentar rápido con productos, quiero resolver el lanzamiento en menos de 2 semanas-equipo, esto debe cumplirse con cada ramo nuevo, para llevar el producto al mercado dentro de la ventana comercial

Escenario de origen	EC012
Atributo	Facilidad de modificación
Fuente	Área de Producto y crecimiento
Estímulo	Se lanza un ramo nuevo de seguro
Artefacto	Catálogo de Productos, componente de Rating, componente de Suscripción y los clientes web y móvil
Ambiente	Operación en mantenimiento
Medida de respuesta	Menos de 2 semanas-equipo

Respuesta	El catálogo define el ramo, sus coberturas y sus reglas como datos versionados, y los clientes web, móvil y embebido lo consumen desde el mismo contrato sin cambios de código

ASR-13: Alta de un socio embebido en una semana

Como integrador técnico de un retailer que quiere vender seguros, cuando solicito conectarme al canal embebido de Solventa, dado que la meta es superar 30 socios de distribución, quiero quedar habilitado en menos de 1 semana, esto debe repetirse con cada socio nuevo, para que el costo de incorporar un aliado deje de crecer con la red

Escenario de origen	EC013
Atributo	Facilidad de integración
Fuente	Equipo de alianzas de Solventa junto con el integrador técnico del socio
Estímulo	Un retailer solicita vender seguros a través de su propio canal vía API
Artefacto	Componente de Socios y Gobierno de API, API Gateway y portal web de socios
Ambiente	Operación normal, con la red de socios existente activa
Medida de respuesta	Menos de 1 semana
Respuesta	El portal de socios emite el contrato de API, las credenciales y los alcances, configura los ramos habilitados y la cuota de consumo, y el socio queda operando sobre la versión vigente del contrato mientras las versiones anteriores siguen en pie

ASR-14: Conexión de una fuente nueva de Open Data

Como líder del equipo de datos, cuando sumo un agregador o una fuente pública nueva de Open Data, dado que el perfilamiento mejora con cada fuente disponible, quiero resolver la conexión en menos de 40 horas/hombre, esto debe cumplirse con cada fuente nueva, para enriquecer el perfil sin frenar la operación

Escenario de origen	EC014
Atributo	Facilidad de integración
Fuente	Equipo de datos de Solventa
Estímulo	Se suma un agregador o una fuente pública nueva de Open Data
Artefacto	Adaptador de fuentes externas del componente de Perfilamiento
Ambiente	Operación en mantenimiento
Medida de respuesta	Menos de 40 horas/hombre
Respuesta	La fuente entra detrás del adaptador estándar, con su propio mapeo y su vigencia de dato, y los consumidores existentes siguen operando sin cambios

7. Riesgos identificados

Cada riesgo parte de una señal explícita del negocio y se traduce en su consecuencia para el proyecto.

Señal identificada	Riesgo y su impacto
"Cada dependencia externa es un punto de fallo y una fuente de latencia"	La degradación de Open Finance o de KYC rompe el presupuesto de latencia de la cotización y el cliente abandona la compra dentro del canal del socio.
"Presupuesto de latencia menor o igual a 300 ms por dependencia"	Un flujo que encadena KYC, datos financieros y pago consume el presupuesto completo, y el objetivo de p95 menor o igual a 400 ms queda expuesto a incumplimiento.
"Toda decisión de suscripción es trazable y reconstruible al 100%"	Sin linaje del dato del perfilamiento, actuaría y el regulador pueden rechazar las pólizas emitidas con precio individualizado, que es el diferenciador del caso insignia.
"El riesgo a evitar es un monolito distribuido: toda la complejidad de lo distribuido sin sus beneficios"	Fronteras mal trazadas dejan al equipo con el costo operativo de varios desplegables y sin el escalamiento selectivo que justifica esa decisión.
"Se pasa de 5 a 50 socios de distribución"	Sin aislamiento de carga por socio, la campaña de un aliado degrada la cotización de los demás y compromete la meta de 30+ socios.
"Un cambio no obliga a redesplegar todos los clientes a la vez"	Un versionado deficiente de la API rompe las apps móviles ya instaladas y obliga a retrabajo simultáneo en web, móvil y socios.
"Las reglas de finanzas abiertas siguen madurando"	Un cambio normativo que atraviese varios componentes encarece cada ajuste y pone en riesgo el cumplimiento ante la Superintendencia Financiera.
"Consulta de coberturas y credenciales aun sin conexión, con sincronización posterior"	Fallos de sincronización del modo offline pierden la evidencia del siniestro capturada en sitio, que es el insumo de la validación antifraude.
"El equipo es reducido y el sistema debe poder crecer"	La complejidad operativa de varios desplegables supera la capacidad del equipo y frena la velocidad de entrega dentro de la ventana del proyecto.
"Control del costo de la nube"	El escalamiento ante picos de 100 veces eleva el gasto por encima de lo previsto y obliga a recortar en otras áreas de la operación.
"Detección y bloqueo del patrón anómalo en menos de 1 s"	Un fraude automatizado sobre siniestros paramétricos dispara pagos indebidos antes de que el control lo detecte.
"Cifrado en tránsito y reposo; tokenización de PII"	Una fuga de datos financieros consentidos deriva en sanciones bajo la Ley 1581 y en pérdida de la confianza que sostiene el modelo de finanzas abiertas.

8. Esfuerzo estimado para construir la aplicación

El esfuerzo incluye actividades, responsables y estimación en horas hombre, sobre una base de 220 horas por mes.

Actividad	Responsable	Esfuerzo Estimado (Horas / Hombre)
Diseñar la arquitectura, incluyendo las pruebas de concepto y los experimentos de arquitectura.	Arquitectos de software (4)	4 meses 880 horas/hombre
Desarrollar el núcleo de negocio: cotización, rating, suscripción, emisión y ciclo de vida de pólizas.	Desarrolladores backend (4)	3 meses 660 horas/hombre
Desarrollar el motor de perfilamiento y los adaptadores de Open Finance, Open Data, KYC y pagos.	Desarrolladores backend (2)	3 meses 660 horas/hombre
Desarrollar el flujo de siniestros y el disparo automático del siniestro paramétrico.	Desarrolladores backend (2)	2 meses 440 horas/hombre
Desarrollar el cliente web de gestión, venta asistida y back-office de socios.	Desarrolladores frontend (2)	3 meses 660 horas/hombre
Desarrollar el cliente móvil iOS y Android con las capacidades propias del canal.	Desarrolladores móvil (2)	3 meses 660 horas/hombre
Habilitar la plataforma de despliegue, observabilidad y automatización.	Ingeniero DevOps y SRE (1)	4 meses 880 horas/hombre
Ejecutar la estrategia de pruebas y los experimentos de carga y resiliencia.	Ingeniero de calidad (1)	2 meses 440 horas/hombre

Total acumulado: 12.320 horas/hombre (responsables por meses por 220 horas al mes).

Base de cálculo: 220 horas por mes por persona.

9. Modelos de arquitectura

La visión de arquitectura se comunica en cuatro modelos: contexto, información, funcional y despliegue. Los tres últimos cubren las vistas exigidas. El diseño detallado de patrones y tácticas, y su relación con los ASR, se documenta en la sección 9.5.

Los modelos de contexto (VC-001) y de información (VC-002) se mantienen en versión 1.0. Los modelos funcional (VC-003) y de despliegue (VC-004) avanzan a versión 2.0: recogen los cambios que los experimentos de la sección 10 dejaron medidos. La sección 11 registra esa evolución en orden, con el origen y la evidencia de cada cambio.

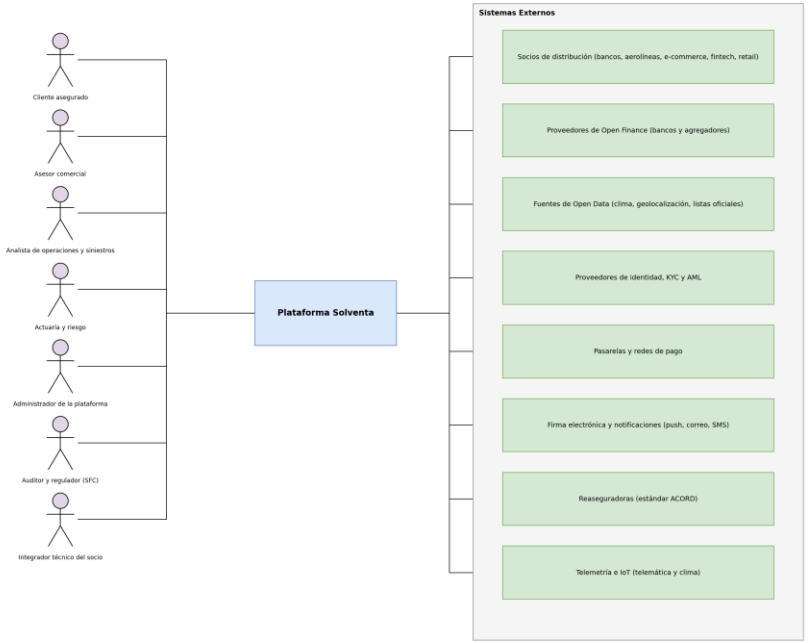
9.1 Modelo de contexto

El modelo de contexto delimita la frontera de la plataforma. A la izquierda quedan los roles que la usan de forma directa, y a la derecha los sistemas externos que aportan o consumen información y que están fuera del control de Solventa. La densidad del lado derecho marca el resto del diseño: la mayoría de las cajas del diagrama corresponden a terceros, y cada uno es a la vez fuente de valor y punto de falla.

Proyecto	Solventa	**ID**	VC-001	**Elaboración**	Grupo 6	**Versión**	1.0
Vista	Información	**Modelo**		Contexto			

Proyecto	Solventa	ID	VC-001	Elaboración	Grupo 6	Versión	2.0
Vista	Información	Modelo	Contexto				

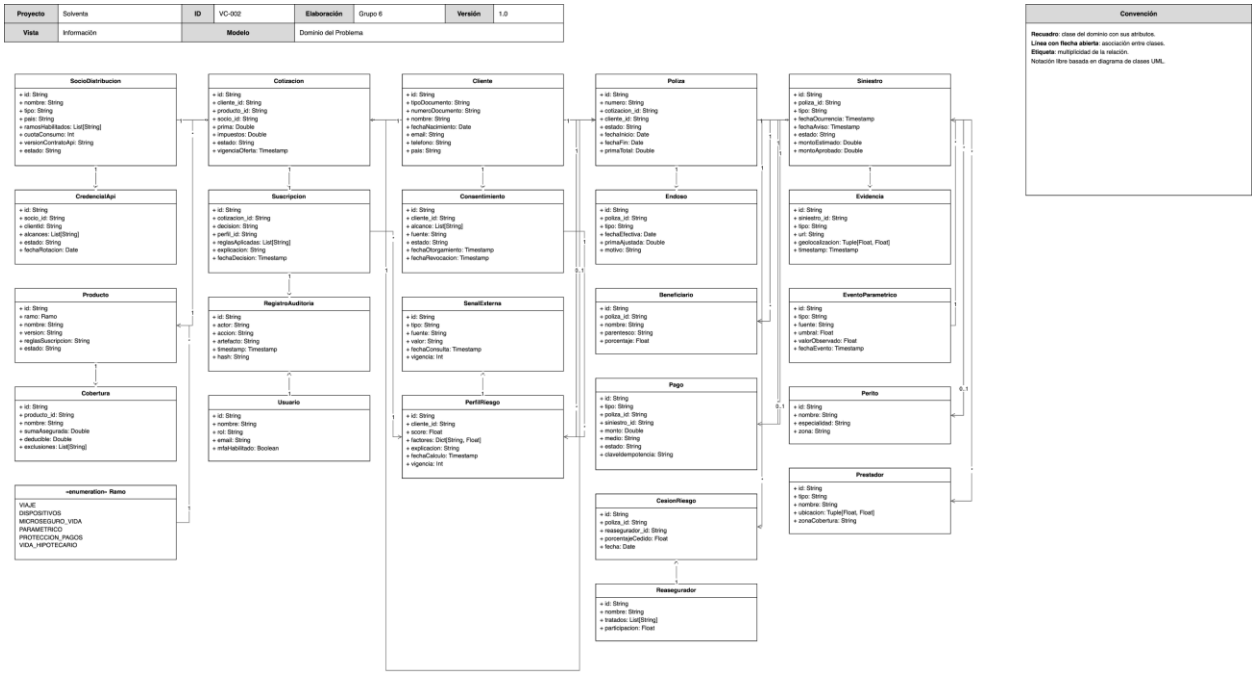
Convención
Actor: usuario o rol que interactúa con la plataforma. Recuadro azul: sistema en construcción (Plataforma Solventa). Recuadro verde: sistema externo fuera del control de Solventa. Línea: relación de intercambio de información.



9.2 Vista de información

La vista de información recoge el modelo de dominio del negocio asegurador y sus relaciones. El recorrido comercial va de Cliente a Cotización, Suscripción y Póliza. El eje de personalización conecta Consentimiento, SenalExterna y PerfilRiesgo, que alimentan la decisión de suscripción y dejan su explicación registrada. El eje operativo cubre Siniestro, Evidencia, EventoParametrico y Pago, con clave de idempotencia en el cobro. SocioDistribucion y CredencialApi sostienen el canal embebido, y RegistroAuditoria conserva la traza de cada decisión. Este modelo es el insumo de la persistencia por capacidad y de las tácticas de réplica, DLQ e idempotencia de la sección 9.5.

Proyecto	Solventa	**ID**	VC-002	**Elaboración**	Grupo 6	**Versión**	1.0
Vista	Información	**Modelo**		Dominio del Problema			



9.2.1 Lectura del modelo de datos

El modelo de dominio muestra las entidades del negocio y no corresponde a una sola base de datos para todo el sistema. Las clases que viven en el mismo almacén, según el mapa de la sección 9.2.2, se guardan juntas: esa base sí puede exigir, por ejemplo, que una cobertura pertenezca a un producto. Cuando una línea une clases de almacenes distintos, cada servicio copia en su propia tabla el identificador que necesita (cliente_id, poliza_id, cotizacion_id), sin consulta cruzada entre bases.

Tres grupos se leen así. Cotización va con Producto y SocioDistribucion en el catálogo. Póliza lleva Endoso y Beneficiario. Siniestro lleva Evidencia: la foto o el PDF viven en el almacén de objetos cuya dirección queda en Evidencia.url. Los tipos List, Dict y Tuple se guardan como JSON o como tablas hijas en la misma base, sobre el mismo motor de datos.

Una cotización puede quedarse en 0..1 respecto a la suscripción. En Pago, siniestro_id es opcional: cobrar la prima solo necesita la póliza, y pagar un siniestro necesita póliza y siniestro. El umbral que dispara un seguro paramétrico está en Cobertura (umbralParametrico), y EventoParametrico anota lo observado con su fuente y su valor. RegistroAuditoria es el historial de toda la plataforma y vive por fuera de Suscripción, Póliza y Siniestro.

Lo que el sistema escribe en el día a día es lo que muestra el modelo. Los reportes actuariales y las consultas de auditoría se leen de réplicas de solo lectura (CQRS), con un solo modelo de negocio y una sola vía de escritura.

9.2.2 Almacenamiento de datos

Cada microservicio es dueño exclusivo de su almacén (Database-per-Service). Los demás servicios leen por API o reciben el estado a través del bus de eventos.

En las tablas siguientes, Tipo describe la clase de almacén, es decir cómo se guardan los datos, y Rol describe la función de ese nodo en la topología. Primaria, réplica y perímetro PCI comparten motor: las bases de dominio son todas relacionales, y lo que cambia es el rol o el perímetro.

Tabla 1. Convención de tipo y rol

Columna	Valor	Significado
Tipo	Base relacional	Tablas SQL. Es el sistema de registro del dominio: la fuente de verdad transaccional.
Tipo	Caché en memoria	Copia temporal de perfil o cotización para responder rápido. No es fuente de verdad.
Tipo	Almacén de objetos	Archivos binarios (fotos, PDFs). La base relacional solo guarda la URL de referencia.
Tipo	Cola de mensajes	Eventos en tránsito entre servicios. No sustituye a la base de datos.
Tipo	Registro de auditoría	Bitácora de hechos. Cada registro se agrega; no se actualiza ni se borra.
Rol	Primaria	Nodo que recibe las lecturas y escrituras del servicio dueño.
Rol	Réplica síncrona (standby)	Copia en otra zona de disponibilidad. No atiende escrituras de negocio; se promueve si cae la primaria.
Rol	Réplica de lectura	Copia para reportes y analítica. No escribe el dominio.
Rol	Primaria, perímetro PCI	Misma tecnología relacional, en una red y con accesos separados por datos de pago.
Rol	Copia de lectura rápida	La caché sirve lecturas calientes; si no hay dato fresco se usa last-known-good.
Rol	Transporte	El bus mueve eventos; no persiste el estado de negocio como sistema de registro.
Rol	Solo inserción	En auditoría solo se inserta. No hay modificación ni borrado de hechos ya registrados.
Rol	Primario de binarios	Guarda el archivo de evidencia. El metadato (Evidencia) vive en la BD de siniestros.

Tabla 2. Mapa de almacenamiento de Solventa

Almacén	Tipo	Rol	Qué guarda	Servicio dueño	Notas de consistencia
BD Cotización y Catálogo	Base relacional	Primaria	Producto, Cobertura, Ramo, Cotización, SocioDistribucion, CredencialApi	Cotización y Rating / Catálogo de Productos	Escritura con transacción. Fuente de verdad de cotizaciones y catálogo.

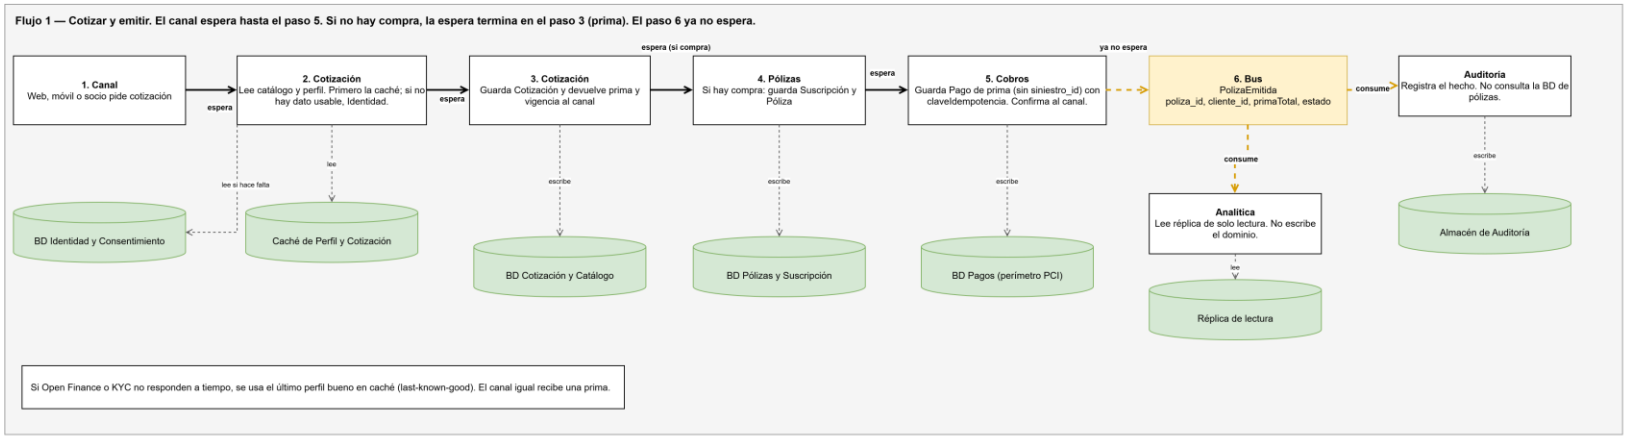
Almacén	Tipo	Rol	Qué guarda	Servicio dueño	Notas de consistencia
BD Pólizas y Suscripción	Base relacional	Primaria	Suscripción, Póliza, Endoso, Beneficiario, CesionRiesgo, Reasegurador	Suscripción / Pólizas y Ciclo de Vida	Escritura con transacción. Fuente de verdad del ciclo de vida de la póliza.
BD Siniestros y Evidencia	Base relacional	Primaria	Siniestro, EventoParametrico, Perito, Prestador; metadatos de Evidencia (url)	Siniestros / Siniestro Paramétrico	Escritura con transacción. Los archivos de evidencia viven en el almacén de objetos; aquí queda su referencia.
Almacén de objetos (evidencia)	Almacén de objetos	Primario de binarios	Archivos referenciados por Evidencia.url	Siniestros	Inmutable tras la carga. La BD relacional solo guarda la URL.
BD Identidad y Consentimiento	Base relacional	Primaria	Cliente, Consentimiento, Usuario, PerfilRiesgo, SenalExterna	Identidad / KYC / Perfilamiento	Escritura con transacción. Fuente de verdad del cliente y su perfil.
BD Pagos (ámbito PCI)	Base relacional	Primaria, perímetro PCI	Pago (incluye claveIdempotencia)	Cobros y Pagos	Misma tecnología relacional; red y accesos separados. Esquema propio.
Caché de Perfil y Cotización	Caché en memoria	Copia de lectura rápida	PerfilRiesgo, SenalExterna y cotizaciones last-known-good	Perfilamiento / Cotización	Consistencia eventual; TTL. No es fuente de verdad.
Bus de eventos	Cola de mensajes	Transporte	Eventos de integración entre servicios	Integración	Entrega al menos una vez; los consumidores son idempotentes.
Almacén de Auditoría y Linaje	Registro de auditoría	Solo inserción	RegistroAuditoria	Auditoría	Los hechos no se modifican ni se borran.
Réplica síncrona Multi-AZ	Base relacional	Réplica síncrona (standby)	Copia de las BD relacionales críticas	Infraestructura / persistencia	Se promueve a primaria si cae la zona activa.
Réplicas de lectura	Base relacional	Réplica de lectura	Mismo esquema que la primaria; reportes actuariales y auditorías	Analítica	Consistencia eventual respecto a la primaria. No escribe el dominio.

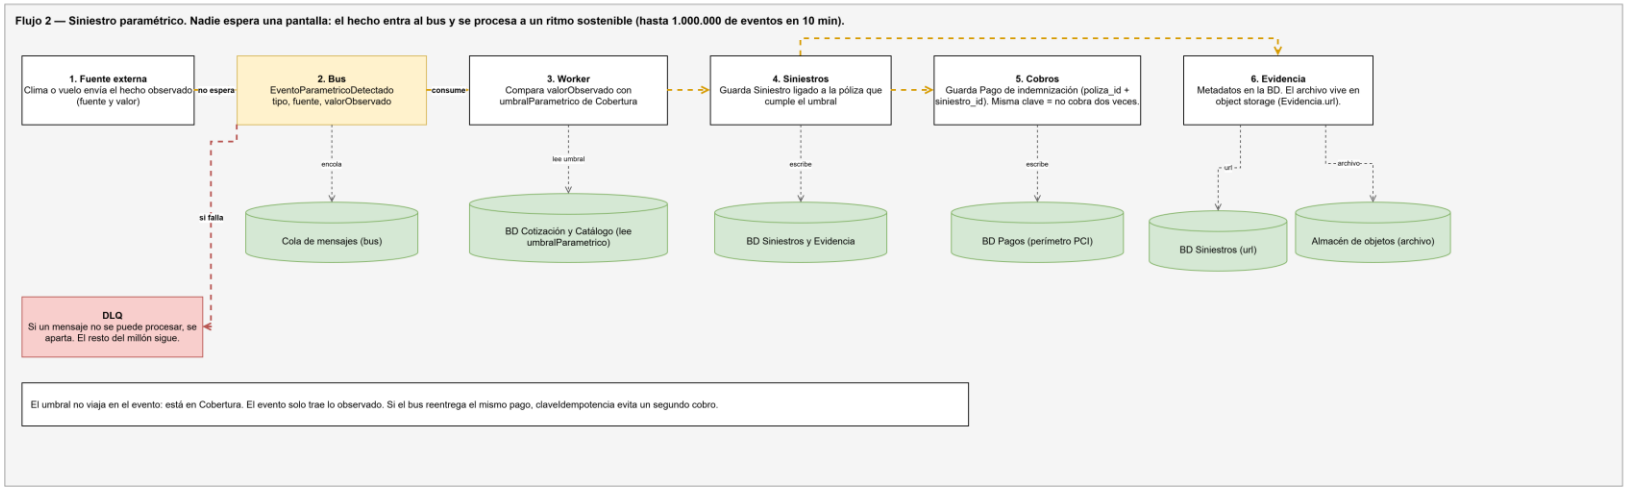
9.2.3 Flujo de datos y control

El flujo muestra cómo se mueven los datos y quién espera. En el Flujo 1, cotizar y emitir, el canal espera hasta que hay prima o, si hay compra, hasta que el pago queda confirmado. En el Flujo 2, el siniestro paramétrico, el hecho entra al bus y se procesa a un ritmo sostenible sin que nadie espere una pantalla.

La flecha negra continua indica que el canal sigue esperando la respuesta. La flecha naranja discontinua es un aviso en el bus, donde el canal ya deja de esperar. Cada cilindro es el almacén de la Tabla 2 donde se lee o se escribe en ese paso.

Proyecto	Solventa	ID	VC-003	Elaboración	Grupo 6	Versión	1.0
Vista	Información	Modelo	Flujo de datos y control				





Convención

Recuadro blanco: paso (quién hace qué).
Cilindro verde: almacén donde se lee o se escribe.
Recuadro amarillo: aviso en el bus de eventos.
Recuadro rojo: cola de mensajes muertos (DLQ).
Flecha continua negra: el canal espera la respuesta.
Flecha discontinua naranja: aviso asíncrono; el canal ya no espera.
Flecha discontinua gris: leer o escribir un almacén.
El evento lleva ids y datos de negocio (prima, estado, valor observado) para no volver a consultar la base de origen.

Ilustración 8. Flujo de datos y control. Flujo 1 de cotización y emisión, y Flujo 2 del siniestro paramétrico con su cola de mensajes muertos.

9.2.4 Esquema de replicación

Cada escritura que se confirma al canal existe en más de un sitio. Hay tres modos, y una sola base acepta escrituras mientras las demás son copias.

La Tabla 3 define los modos y la Tabla 4 dice qué almacén usa cada uno. Esa lista es la completa: el modelo de componentes dibuja dos réplicas, Cotización y Pólizas, para conservar la legibilidad del diagrama.

Tabla 3. Modos de replicación

Modo	Dónde	¿El canal espera?	Si cae el origen
Síncrona (otra zona)	Misma región, otra zona de disponibilidad	Sí: el dato se confirma al canal una vez está en las dos zonas	Esa copia pasa a primaria y se conserva lo ya confirmado. El servicio vuelve en 10 minutos o menos.
Asíncrona (otra región)	Región secundaria	No	Se arranca en la otra región, con un máximo de 30 segundos de datos aún no copiados.
Solo lectura	Copia extra para reportes y auditoría	No	Sirve para consulta. El negocio del día a día se escribe en la primaria.

Tabla 4. Replicación por almacén

Almacén	Otra zona (misma región)	Otra región	Nota
BD Cotización y Catálogo, BD Pólizas y Suscripción, BD Siniestros y Evidencia, BD Identidad y Consentimiento, BD Pagos	Síncrona	Asíncrona	Las cinco primarias relacionales. Pagos sigue en el perímetro PCI.
Almacén de objetos (evidencia)	Copia en la otra zona	Copia en la otra región	El archivo tiene que existir donde apunta la url de Evidencia.
Bus de eventos	Replicado	Replicado	Sostiene los avisos del Flujo 2, el siniestro paramétrico.
Caché de Perfil y Cotización	No aplica	No aplica	Se reconstruye desde la BD o se usa last-known-good.
Réplica de lectura	No aplica	No aplica	Copia extra, con retraso deliberado. Solo reportes y auditoría.
Almacén de Auditoría	Síncrona	Asíncrona	Los hechos se copian y conservan intactos.

9.3 Vista funcional

La vista funcional organiza la solución en cinco capas: clientes; exposición por canal con BFF web, BFF móvil y API pública de socios, más el monitor de salud y retiro; lógica de negocio en microservicios alineados con las capacidades, con cotización redundante, validador de consenso y workers de absorción de picos; integración con un adaptador por tercero, circuit breaker global y bus de eventos; y persistencia con un almacén por capacidad, caché de perfil y réplicas síncronas multi-zona. El estilo es microservicios por capacidad de negocio, comunicación asíncrona por eventos y un backend por experiencia en cada canal.

La versión 2.0 del modelo declara los conectores con notación UML 2.0. El API Gateway enruta con «route» hacia BFF Web, BFF Móvil y API Pública de Socios. Entre microservicios y adaptadores la invocación síncrona va con «call». El Bus de Eventos recibe «publish» de Siniestros, Siniestro Paramétrico y Cobros y Pagos, y entrega «subscribe» a Analítica, Fraude y Cumplimiento, Auditoría y Linaje del Dato y Siniestro Paramétrico. La persistencia va con «persist» hacia el almacén dueño, y la replicación primaria a réplica con «replicate». El Circuit Breaker Global agrega cada adaptador externo con un diamante hueco. El Monitor de Salud y Retiro envía heartbeat a Cotización y Rating y a Siniestros.

Dos componentes entran por el Experimento 2. El Idempotency Key Validator valida la clave única por evento antes de que Siniestro Paramétrico liquide, y es esa validación la que sostiene una sola liquidación por evento bajo reentregas y consumo concurrente. La Dead Letter Queue queda separada del Bus de Eventos como pieza propia, con su política de reintento visible en el conector: un evento irrecuperable pasa a esa cola tras tres intentos y el drenado del pico sigue su curso.

Proyecto	Solventa	**ID**	VC-003	**Elaboración**	Grupo 6	**Versión**	2.0
Vista	Funcional	**Modelo**		Componentes			

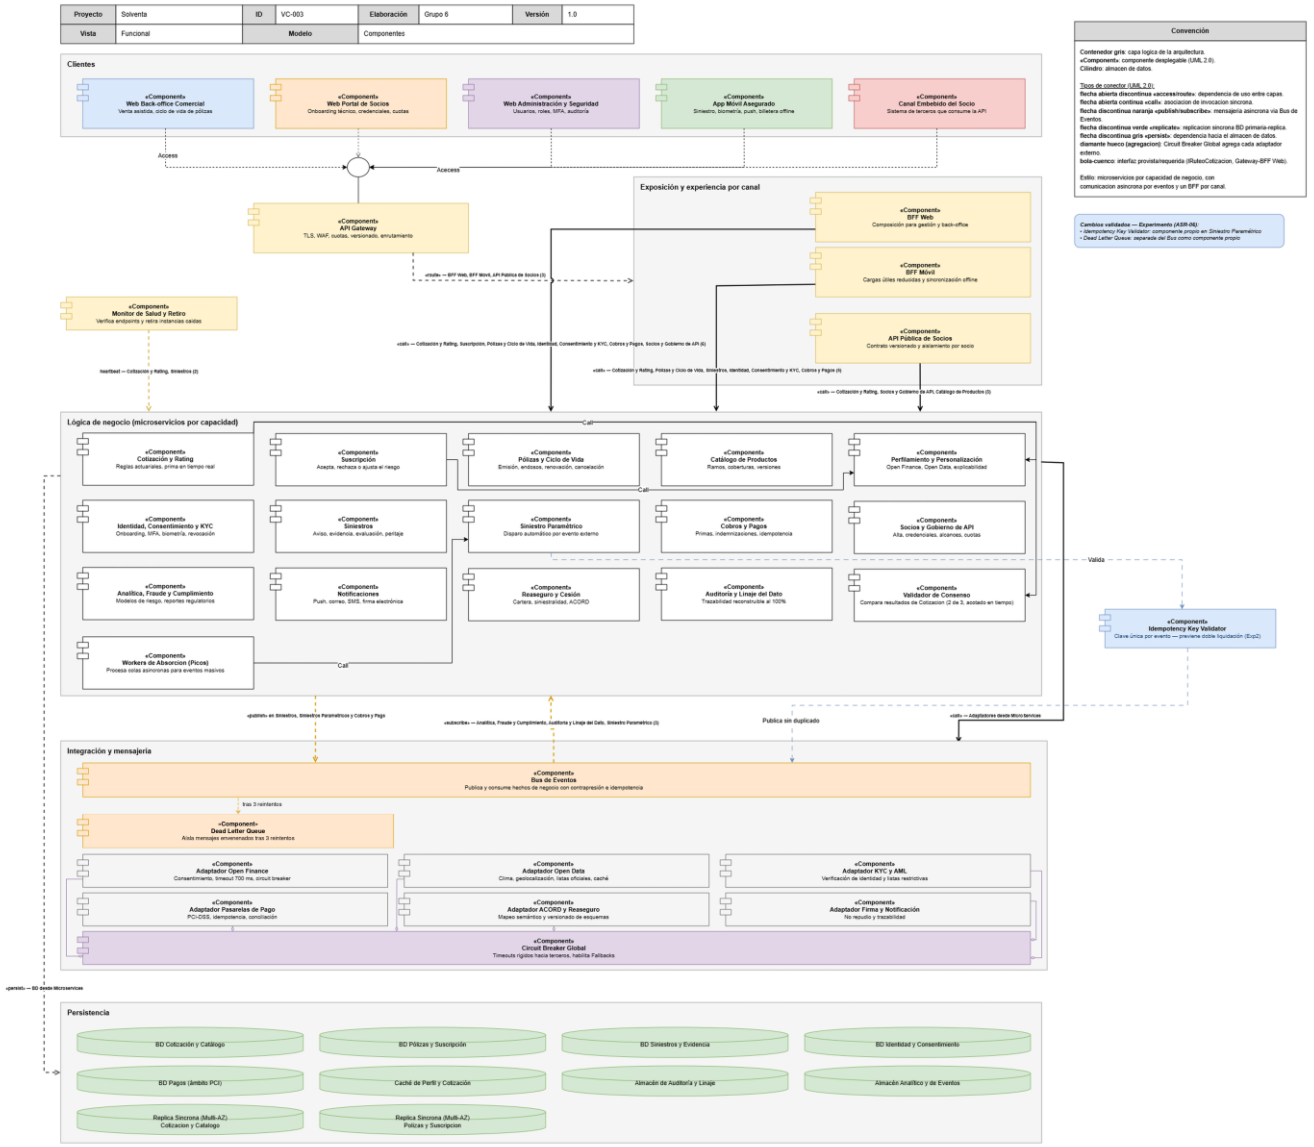


Ilustración 1. Modelo de componentes VC-003, versión 2.0. Incorpora los conectores UML 2.0, el Idempotency Key Validator, la Dead Letter Queue y las réplicas síncronas multi-zona.

Visualización del modelo de componentes: [abrir diagrama]

9.4 Vista de despliegue

La vista de despliegue asigna el software a una nube elástica, multi-zona y con región secundaria. El borde concentra CDN, WAF, balanceador global y API Gateway. La región primaria opera activo-activo en dos zonas, cada una con clúster de contenedores, nodo de mensajería, caché en memoria y base relacional (primaria en una zona, réplica síncrona en la otra). La región secundaria queda en espera, con réplica asíncrona, para el failover de región (RTO menor o igual a 5 minutos, sin pérdida de transacciones confirmadas). Los terceros se consumen por HTTPS con timeout, reintentos y circuit breaker, fuera de la red propia.

La versión 2.0 del despliegue incorpora tres piezas que la medición dejó justificadas. El Health Monitor queda como artefacto propio en el borde de red y envía latidos por debajo de 500 ms a cada nodo de las dos zonas, sobre una ruta TCP/IP marcada como health-check. Cada zona de disponibilidad aloja un nodo «Workers Siniestro Paramétrico» con N réplicas en Competing Consumers. Un Auto-Scaling Group (KEDA o AWS ASG) ajusta esas réplicas leyendo la profundidad de la cola por la métrica ApproximateNumberOfMessagesVisible. Entre los workers y la base relacional de cada zona queda un nodo Connection Proxy (PgBouncer o AWS RDS Proxy) que agrupa las conexiones y sostiene la concurrencia de escritura cuando el número de réplicas crece.

Los nodos quedan tipificados con «environment», «execution environment» y «node», y el software desplegado con «artifact». La base primaria y su réplica declaran «Master» y «Réplica síncrona», y la región secundaria declara «Réplica asíncrona» sobre el clúster pasivo.

Proyecto	Solventa	**ID**	VC-004	**Elaboración**	Grupo 6	**Versión**	2.0
Vista	Despliegue	**Modelo**		Despliegue			

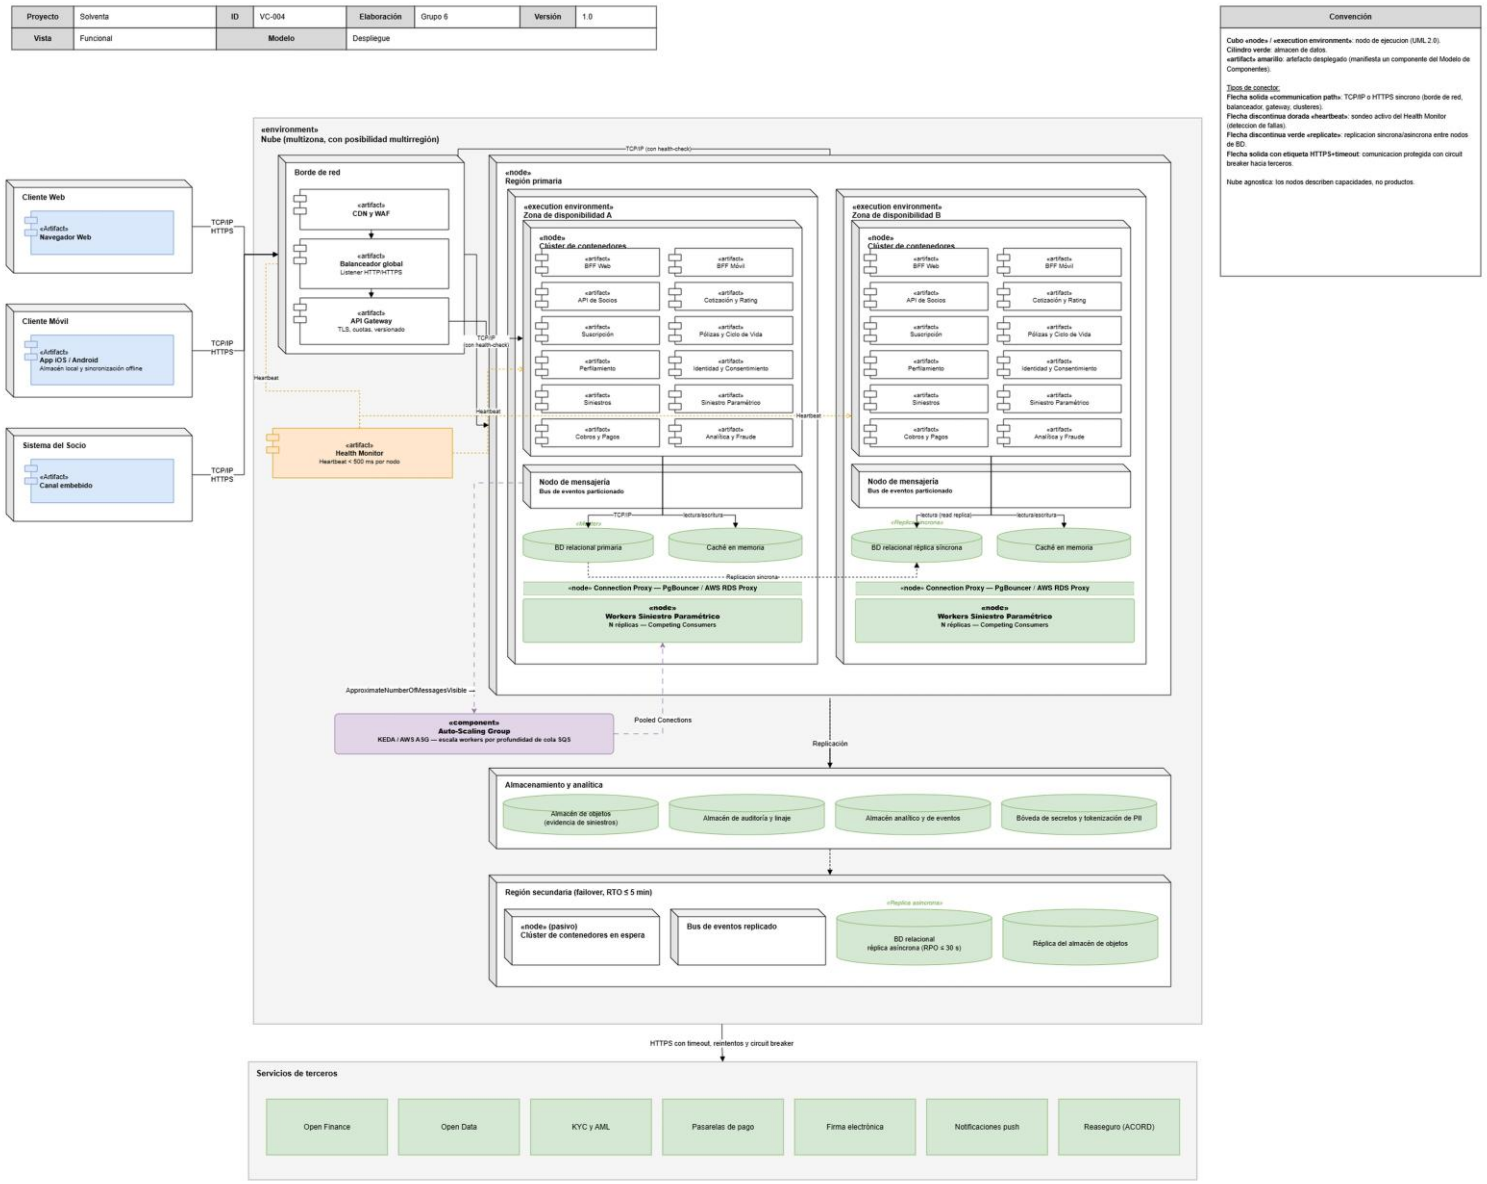


Ilustración 2. Modelo de despliegue VC-004, versión 2.0. Incorpora el Health Monitor con heartbeat, los nodos de Workers Siniestro Paramétrico, el Connection Proxy por zona y el Auto-Scaling Group por profundidad de cola.

9.5 Diseño detallado de arquitectura

El diseño detallado aplica patrones y tácticas de Bass sobre las tres vistas. Cada elección se justifica por el ASR que debe sostener, no por moda. A continuación se declara el patrón, la decisión de diseño, el razonamiento y los ASR que habilita.

9.5.1 Patrones sobre la vista funcional

A continuación, se detalla la justificación de las decisiones tomadas en el modelo y su relación directa con los ASRs del proyecto:

1. Monitor de Salud y Retiro Automático

- **Componente en el Modelo:** Monitor de Salud y Retiro (Capa de Exposición / API Gateway).
- **ASRs Habilitados:**
    - ASR-07: Disponibilidad de los flujos críticos ≥ 99,97%
    - ASR-08: Recuperación ante la caída de una zona con RTO ≤ 10 min
- **Decisión:** Se integró un monitor de salud activo a nivel del enrutador (API Gateway). Este componente realiza sondeos a los microservicios de la capa lógica.
- **Razonamiento:** Permite identificar inmediatamente si una instancia de un servicio (ej. Suscripción o Perfilamiento) está degradada. Evita enrutar peticiones hacia instancias fallidas. Al retirar el nodo enfermo de forma automática, el sistema mantiene la disponibilidad general y cumple con el RTO exigido al conmutar el tráfico sano a las zonas restantes sin intervención manual.
- **Patrón de diseño:** Health Endpoint Monitoring
  Es más económico y rápido para sondear activamente el estado de cada uno de los nodos, antes de esperar que el propio cliente reporte una falla; evita además implementar un protocolo de consenso distribuido para un problema que es, en el fondo, de simple disponibilidad.

2. Votación Redundante / Consenso

- **Componente en el Modelo:** Cotización (Instancias Redundantes) y Validador de Consenso (Capa de Lógica de Negocio).
- **ASRs Habilitados:**
    - ASR-07: Disponibilidad de los flujos críticos ≥ 99,97%
    - ASR-05 y ASR-01: Disponibilidad de flujos sin comprometer el presupuesto
- **Decisión:** El cálculo de la prima de riesgo (Cotización y Rating) se instanció de manera redundante (x3) con un validador intermedio.
- **Razonamiento:** Previene fallos bizantinos o corrupciones en memoria. Si una instancia calcula mal la prima, el Validador compara los resultados de las tres instancias y emite el resultado mayoritario. Garantiza que el usuario (y los socios) siempre reciban una cotización válida, elevando la confiabilidad de la operación comercial central para cumplir el SLA del 99,97%.
- **Patrón de diseño:** Redundancia N+1 activo-activo, con comparación acotada en tiempo (no un consenso bizantino completo)
  Un consenso bizantino clásico (mínimo 3f+1 réplicas) está pensado para tolerar nodos maliciosos o adversarios, que no es el riesgo real aquí; el riesgo real es un bug puntual o corrupción de memoria en una instancia, y un esquema de “dos de tres” acotado en tiempo cubre ese riesgo sin pagar la latencia de un protocolo de consenso completo.

3. Circuit Breaker Global y Caché Fallback

- **Componente en el Modelo:** Circuit Breaker Global (Capa de Integración) y Caché de Perfil y Cotización (Capa de Persistencia).
- **ASRs Habilitados:**
    - ASR-01 y ASR-02: Latencia de cotización y perfilamiento con p95 ≤ 400 ms
    - ASR-03: Presupuesto de latencia por dependencia externa con p95 ≤ 300 ms
    - ASR-10: Continuidad ante la degradación de un proveedor externo
- **Decisión:** Se envolvió la comunicación de los adaptadores de integración (Open Finance, KYC) en un Cortacircuitos con timeouts rígidos (300 ms - 3000 ms dependiendo del ASR). Si ocurre una falla o lentitud, el circuito se abre y se usa el Caché como fallback.
- **Razonamiento:**
    - Control de Latencia (ASR-03): Corta explícitamente las llamadas lentas para proteger el presupuesto de latencia global (ASR-01/02).

    - Disponibilidad Degradada (ASR-10): Si un tercero (ej. buró de crédito) colapsa, Solventa no colapsa. El modelo utiliza los datos cacheados para ofrecer una respuesta rápida, sacrificando frescura de datos, pero garantizando la disponibilidad del flujo de venta de cara al usuario.
- **Patrón de diseño:** Circuit Breaker + Cache-Aside (last-known-good)
  El Circuit Breaker es el patrón estándar para llamadas salientes a un tercero sin SLA garantizado, porque corta el fallo en el origen antes de que se propague; el Cache-Aside lo complementa porque devolver un dato "suficientemente bueno" desde caché es preferible a fallar por completo cuando Solventa no controla la disponibilidad del proveedor externo.

4. Workers de Absorción de Picos (Táctica de Latencia y Escalabilidad)

- **Componente en el Modelo:** Workers de Absorción (Picos) y Bus de Eventos (Capa de Lógica e Integración).
- **ASRs Habilitados:**
    - ASR-06: Absorción de un evento paramétrico masivo: 1.000.000 de eventos en 10 min
- **Decisión:** Extraer el procesamiento masivo (como el Siniestro Paramétrico) de los hilos síncronos hacia Workers que consumen mensajes encolados asíncronamente desde el Bus de Eventos.
- **Razonamiento:** Ante un evento climático masivo, una API tradicional se saturaría, elevando la latencia a niveles críticos o cayendo por falta de memoria. El bus retiene los eventos, aplica contrapresión sobre los consumidores (Workers), y estos procesan de manera idempotente a un ritmo sostenible, garantizando el ASR-06 sin afectar la latencia de los canales de venta.
- **Patrón de diseño:** Competing Consumers + Idempotent Receiver
  Competing Consumers permite escalar el consumo horizontalmente sin coordinar particiones a mano (cada worker toma el siguiente mensaje disponible); y como el bus entrega con semántica "al menos una vez", sin Idempotent Receiver un reintento duplicaría el procesamiento de un mismo siniestro paramétrico.

5. Réplicas Síncronas Multi-AZ (Táctica de Disponibilidad)

- **Componente en el Modelo:** Réplica Síncrona (Multi-AZ) (Capa de Persistencia).
- **ASRs Habilitados:**
    - ASR-08: Recuperación ante la caída de una zona con RTO ≤ 10 min
    - ASR-09: Pérdida de datos ante la caída de una zona con RPO ≤ 30 s
- **Decisión:** Cada base de datos primaria cuenta con un cilindro de réplica síncrona aprovisionada en una Zona de Disponibilidad (AZ) diferente.
- **Razonamiento:**
    - RPO (ASR-09): Al ser replicación síncrona, cualquier transacción confirmada al cliente ya existe en al menos dos ubicaciones físicas. Si la zona colapsa, se conserva la información y los pagos idempotentes, asegurando un RPO ≤ 30s.
    - RTO (ASR-08): El clúster de base de datos puede promover la réplica a primaria casi de inmediato, garantizando el restablecimiento del servicio sin intervención manual en menos de 10 minutos.
- **Patrón de diseño:** Master-Slave Replication (réplica primaria-secundaria síncrona)
  Es el esquema más simple y probado para lograr un RPO bajo sin necesitar quorum de escritura; Solventa no necesita escribir simultáneamente en dos zonas, así que no se justifica pagar la complejidad de resolución de conflictos de un esquema multi-master.

9.5.2 Patrones sobre la vista de despliegue

Para que Solventa soporte picos masivos de cotizaciones y pueda restablecer el servicio en menos de 10 minutos ante un desastre (ASR-03 y ASR-05), no bastaba un despliegue básico: la topología tuvo que evolucionar hacia una infraestructura explícitamente distribuida y monitoreada.

- **Estilos de Arquitectura Seleccionados:**
    - **Estilo N-Niveles a nivel de infraestructura:** Decidimos aplicarlo directamente a nivel de infraestructura. Separamos de forma muy clara nuestras capas: el borde de red (donde están el API Gateway y el WAF), la capa de cómputo (nuestros clústeres de contenedores) y el almacenamiento (bases de datos y caché). Al no mezclar responsabilidades, cada nivel puede escalar de forma horizontal e independiente justo cuando la carga lo exige, sin arrastrar a los demás – ASR-03.
    - **Estilo de Asignación / Despliegue:** Mapeamos nuestro software a la infraestructura real dividiendo nuestros microservicios en múltiples zonas de disponibilidad (Activo-Activo) y sumamos una región secundaria en modo Activo-Pasivo. Si un centro de datos entero se cae, Solventa ni se entera - ASR-05.
- **Tácticas de disponibilidad y latencia a implementar**

- **Detección agresiva – ASR-05:** No esperamos a que un usuario nos reporte un error. Implementamos un monitor que envía "latidos" a nuestros contenedores cada 500 milisegundos. Si un nodo empieza a colgarse, el balanceador lo detecta y lo retira al instante.
  Patrón de diseño: Health Monitor y Heartbeats
  Es más económico y rápido sondear activamente el estado de cada nodo que esperar a que un cliente reporte una falla; además evita implementar un protocolo de consenso distribuido, innecesario para un problema de simple disponibilidad/caída.
- **Protección proactiva – ASR-01, ASR-02, ASR-06:** Como dependemos de terceros como Open Finance o la pasarela de pagos, si ellos fallan, nos pueden tumbar. Con esta táctica, si el proveedor externo se degrada, "abrimos el circuito" y cortamos la conexión de raíz para proteger nuestra plataforma.
  Patrón de diseño: Circuit Breaker
  Es el patrón estándar de la industria para llamadas salientes a terceros sin SLA garantizado: corta el fallo en el punto de origen, en lugar de dejar que hilos y conexiones se acumulen esperando una respuesta que no llega y terminen tumbando también los servicios propios.
- **Enmascaramiento de fallas – ASR-06:** La experiencia del cliente es intocable. Si Open Data se demora, no dejamos al usuario mirando una pantalla de carga; el sistema consulta un clúster de Redis y devuelve la última cotización válida conocida (last-known-good) de forma casi instantánea.
  Patrón de diseño: Fallback Cache, Cache-Aside
  Es la forma más simple de dar una respuesta razonable cuando el dato fresco no está disponible, sin tener que mantener una réplica activa del proveedor externo (algo que Solventa no controla ni puede garantizar).
- **Control de tiempos – ASR-01:** Le pusimos un freno a las dependencias. Configuramos timeouts duros (por ejemplo, a los 700 ms para Open Finance y un máximo absoluto de 3000 ms) para asegurar que ningún tercero se consuma nuestro presupuesto de tiempo.
  Patrón de diseño: Timeouts estrictos (Parte de Circuit Breaker)
  Sin un límite explícito, una sola dependencia lenta puede consumir todo el presupuesto de 400 ms de la cotización y dejar margen cero para el resto de la cadena; el timeout obliga a que cada dependencia respete su cuota.
- **Introducción de concurrencia – ASR-03:** Para manejar las 50.000 cotizaciones por minuto, el despliegue mantiene múltiples copias de procesamiento corriendo en paralelo, distribuyendo la carga de trabajo fluidamente.
  Patrón de diseño: Bulkhead (aislamiento de capacidad por réplica/zona)
  Particionar la capacidad por réplica/zona evita que el pico de tráfico de un socio agote los recursos compartidos que otros socios necesitan; es el mismo principio de los compartimentos estancos de un barco: una fuga no hunde el resto del casco.

9.5.3 Patrones sobre la vista de información

Para nuestro Modelo de Datos y al ser Solventa una plataforma greenfield tenemos la ventaja de implementar una capa de datos de acuerdo como al dominio del negocio dicta exactamente cómo se estructuran y persisten los datos, sin adaptaciones forzadas a sistemas legados.

- **Estilos de Arquitectura Seleccionados**
  - **Base de Datos por Servicio – Database-per-Service:** las entidades centrales del dominio (Cliente, Póliza, Perfil de Riesgo, Siniestro) se agrupan por capacidad de negocio, y cada microservicio (Cotización, Siniestros, Suscripción) es dueño exclusivo de su propio subconjunto de datos. Si la base de Siniestros falla, el motor de Cotización no se entera y la venta de pólizas sigue en pie — ASR-05, y además favorece la facilidad de modificación de ASR-07/ASR-08 al no compartir esquema entre servicios.
  - **Estilo Orientado a Eventos y Memoria Compartida:** Para que estos dominios independientes interactúen sin generar cuellos de botella en la persistencia durante eventos de alto tráfico, los integramos usando un bus de eventos y cachés compartidas para mitigar los cuellos de botella cuando hay eventos masivos - ASR-04, ASR-06.
- **Tácticas de Disponibilidad y Latencia Para Implementar**
  - **Copias múltiples de datos (Réplicas Master/Slave y Backups) – ASR-05:** Como la disponibilidad es innegociable, las bases de datos relacionales críticas operan con replicación síncrona. En caso de que el nodo Master falle, la réplica asume el control casi instantáneamente. Esto nos asegura que el Punto Objetivo de Recuperación (RPO) sea menor a 30 segundos y que no se pierdan datos vitales. Además, mantenemos backups constantes como punto de restauración.
    Patrón de diseño: Master-Slave Replication

Es el esquema más simple y probado para lograr un RPO bajo sin necesitar quorum de escritura; como Solventa no necesita escribir simultáneamente en dos zonas, no se justifica pagar la complejidad de resolución de conflictos de un esquema multi-master.

- **Cola de Mensajes Muertos (DLQ - Dead Letter Queue) - ASR-04, ASR-06:** En un sistema distribuido, las cosas fallan. Si un evento de nuestro dominio no puede procesarse (por ejemplo, un pago fallido o un siniestro paramétrico no resuelto), no permitimos que bloquee el flujo; lo aislamos en una DLQ conectada al Bus de Eventos. Esto asegura que el ecosistema siga operando sin bloqueos.
  Patrón de diseño: Dead Letter Queue
  Sin esta cola, un solo mensaje mal formado o irrecuperable ('envenenado') bloquearía el procesamiento de todos los eventos válidos que vienen detrás de él; aislarlo permite seguir avanzando y revisarlo aparte.
- **Idempotencia – ASR-04:** Esta es vital para los pagos. Si el sistema hace un reintento automático por un fallo de red, usamos llaves de idempotencia para asegurar que jamás se le cobre dos veces al cliente ni se dupliquen pólizas.
  Patrón de diseño: Idempotent Receiver
  El Bus de Eventos entrega mensajes con semántica 'al menos una vez', por lo que un reintento duplicado es normal y esperado; sin este patrón, cualquier reentrega duplicaría un cobro o una póliza en lugar de simplemente ignorarse.
- **Manejo de recursos (Réplicas de Lectura / Read Replicas) – ASR-01:** Para proteger la experiencia de cotización, separamos físicamente el tráfico transaccional rápido del tráfico analítico. Las operaciones pesadas, como la generación de reportes actuariales o las auditorías, se desvían directamente a las réplicas de lectura. De esta manera, el modelo de datos principal queda libre para responder a las nuevas ventas a toda velocidad y no ralentiza al usuario final.
  Patrón de diseño: CQRS (segregación de lectura y escritura)
  Separar el modelo de lectura del de escritura permite optimizar cada uno por separado (índices distintos, réplicas dedicadas) sin arriesgar la consistencia transaccional del lado de escritura, que es el que sostiene el presupuesto de latencia de ASR-01.
- **Consistencia Eventual – ASR-04:** Aceptamos que no todos los datos tienen que estar sincronizados en el microsegundo exacto. El sistema responde de inmediato al cliente y delega las tareas pesadas para que se procesen en segundo plano a través de eventos, dándole al usuario una sensación de inmediatez total.
  Patrón de diseño: Event-Carried State Transfer
  Propagar el estado dentro del propio evento evita que cada consumidor tenga que volver a consultar al servicio origen para completar la información; reduce el acoplamiento síncrono entre microservicios y evita que una cascada de llamadas retrase el procesamiento del evento paramétrico.

9.5.4 Relación de los patrones con los ASR

Las secciones 9.5.1 a 9.5.3 ya justifican cada patrón. Esta tabla no agrega requisitos nuevos: resume, en una sola lectura, qué patrón de qué vista sostiene cada ASR del backlog.

Patrón o estilo	Vista	ASR que sostiene
Monitor de salud y retiro automático	Funcional y despliegue	ASR-07, ASR-08
Votación redundante / consenso	Funcional	ASR-07
Circuit breaker y caché de respaldo	Funcional y despliegue	ASR-01, ASR-02, ASR-03, ASR-10
Workers de absorción y bus de eventos	Funcional	ASR-06, ASR-01
Réplicas síncronas multi-zona y failover de región	Funcional, despliegue e información	ASR-08, ASR-09
N niveles y autoescalado del cómputo	Despliegue	ASR-04, ASR-05
Base de datos por servicio	Información	ASR-07, ASR-12

Patrón o estilo	Vista	ASR que sostiene
Eventos, DLQ e idempotencia	Información	ASR-06, ASR-07, ASR-08, ASR-09
Réplicas de lectura	Información	ASR-01, ASR-04

10. Experimentos

10.1 Experimento 1 — Continuidad de la cotización ante la caída de una instancia

10.1.1 Definición del experimento

Título del experimento	Continuidad de la cotización ante la caída de una instancia
Propósito del experimento	Validar que una instancia fallida de Cotización y Rating sea detectada y retirada del balanceo sin detener el flujo.
Resultados esperados	Al detener una de las dos instancias, el tráfico debe continuar por la réplica sana. Se medirán el tiempo de detección/retiro y las solicitudes fallidas durante la conmutación.
Recursos requeridos	• JMeter • Dos instancias de Cotización y Rating • Balanceador y monitor de salud • Docker • Ambiente de pruebas en AWS • Computadores locales
Elementos de arquitectura involucrados	ASR asociado: ASR-07 - Disponibilidad de los flujos críticos. Elementos: API Gateway / balanceador, Monitor de Salud y Retiro y dos instancias de Cotización y Rating. Vista y modelo: Vista funcional - Modelo de componentes; Vista de despliegue. Punto de sensibilidad: intervalo y umbral del health check para retirar una instancia fallida.
Esfuerzo estimado	48 horas/hombre: 4 integrantes, 12 horas por integrante.

10.1.2 Hipótesis de diseño

Hipótesis de diseño	
Punto de sensibilidad	**Validar el intervalo y el umbral del health check usado para retirar una instancia de Cotización y Rating que deja de responder.**
Historia de arquitectura asociada	ASR-07: Disponibilidad de los flujos críticos Como cliente asegurado de Solventa, cuando compro un seguro o reporto un siniestro a cualquier hora, dado que la plataforma opera 24/7 y el siniestro no espera horario, quiero una disponibilidad mensual mayor o igual a 99,97% en los flujos críticos, esto debe medirse mes a mes, para que el canal esté en pie cuando lo necesite.
Nivel de incertidumbre	Medio. El diseño ya define redundancia y retiro automático, pero todavía no sabemos cuántas solicitudes pueden fallar mientras se detecta la caída y se actualiza el balanceo.

10.1.3 Estilos de arquitectura asociados al experimento

Estilos de Arquitectura asociados al experimento	Análisis (Atributos de calidad que favorece y desfavorece)
Microservicios por capacidad de negocio	Favorece: • Disponibilidad: una instancia puede fallar sin tumbar el servicio. • Escalabilidad: se agregan réplicas de Cotización y Rating. Desfavorece: • Operabilidad: hay más instancias por monitorear.

10.1.4 Tácticas de arquitectura asociadas al experimento

Tácticas de Arquitectura asociadas al experimento	Descripción
Ping/Echo - detección de fallas	El balanceador consulta periódicamente el endpoint de salud de cada instancia y marca como no saludable la que deja de responder.
Redundancia activa	Dos instancias atienden el mismo servicio. Si una falla, el tráfico continúa por la réplica sana sin intervención manual.

10.1.5 Patrones de arquitectura asociados al experimento

Patrones de Arquitectura asociados al experimento	Descripción
Health Endpoint Monitoring	El enrutador sondea activamente el endpoint de salud de cada nodo y retira de forma automática la instancia degradada, sin esperar a que el cliente reporte la falla.
Redundancia N+1 activo-activo	Réplicas activas del servicio de Cotización y Rating atienden en paralelo; si una cae, la otra sostiene el flujo sin intervención manual.

10.1.6 Componentes involucrados en el experimento

Listado de componentes involucrados en el experimento		
Componente	**Propósito y comportamiento esperado**	**Tecnología asociada**
API Gateway + Monitor de Salud y Retiro	Balancear el tráfico, ejecutar health checks y dejar de enviar solicitudes a una instancia caída.	Proxy
Cotización y Rating (2 instancias)	Responder cotizaciones en paralelo. Al detener una instancia, la otra debe continuar atendiendo.	Python 3 + FastAPI

10.1.7 Conectores involucrados en el experimento

Listado de conectores involucrados en el experimento		
Conector	**Comportamiento deseado en el experimento**	**Tecnología asociada**
HTTP/HTTPS síncrono - cliente	JMeter envía solicitudes al balanceador durante toda la prueba.	HTTP/HTTPS
HTTP síncrono - servicio	El balanceador envía cada solicitud únicamente a instancias saludables.	HTTP
Health check	El monitor consulta el endpoint de salud y retira una instancia cuando supera el umbral de fallas.	HTTP

10.1.8 Tecnología asociada con el experimento

Tecnología asociada con el experimento (Desarrollo, infraestructura, almacenamiento)	Justificación
Lenguajes de programación	Python 3 para el servicio mínimo de Cotización y Rating.
Plataforma de despliegue	AWS sobre capa gratuita o créditos académicos.
Contenedores	Docker para levantar las dos instancias de forma repetible.
Balanceo y monitoreo	Proxy para routing, health checks y retiro automático.
Herramientas de análisis	JMeter y logs con marcas de tiempo.
Frameworks de desarrollo	FastAPI para Cotización y Rating.

10.1.9 Distribución de actividades por integrante

Distribución de actividades por integrante		
Integrante	**Tareas a realizar**	**Esfuerzo estimado**
Nicolás	Implementar Cotización y Rating y levantar las dos instancias en Docker.	12 horas
Daniel	Configurar proxy, health checks y el retiro de la instancia fallida.	12 horas
Jerson	Preparar Docker Compose y desplegar el ambiente de prueba en AWS.	12 horas
Jonatan	Preparar JMeter, ejecutar las fallas y consolidar los resultados.	12 horas

10.1.10 Ejecución del experimento

El experimento corre sobre minikube, en el namespace solventa. Un Deployment de Cotización y Rating con dos réplicas expone POST /cotizaciones y GET /health. Un Deployment de nginx con una réplica actúa como API Gateway y enruta al Service ClusterIP cotizacion, que lista únicamente los Pods en estado Ready. kubelet sondea GET /health con el readinessProbe. El Deployment omite el livenessProbe para que la medición aísle el retiro por salud del self-healing de Kubernetes.

La falla se inyecta dentro de un Pod concreto con el script scripts/inyectar_falla.py, que ejecuta kubectl exec y hace POST a /experimentos/falla-salud en 127.0.0.1:8000. El proceso sigue vivo y únicamente /health pasa a responder 503. El script registra el instante UTC y espera hasta que el Pod quede en Ready=false. Inyectar por el gateway habría golpeado cualquier réplica sana, y kubectl delete pod habría medido la recreación del Pod en lugar del probe.

Plan de carga

Parámetro	Valor usado en las corridas
Destino	POST http://127.0.0.1:8080/cotizaciones (gateway con port-forward)
Cuerpo	{"cliente_id":"c-1","ramo":"viajes"}
Hilos	5, con rampa de 5 s
Vueltas por hilo	360
Pausa entre muestras	400 ms (ConstantTimer)
Ritmo observado	Cerca de 12 solicitudes por segundo
Duración	2 min 33 s
Samples por corrida	1.800

Parámetro	Valor usado en las corridas
Variable extraída	$.instancia, el nombre del Pod que respondió
Plan	jmeter/cotizaciones.jmx, ejecutado en modo no gráfico

Configuración del readiness probe por corrida

Parámetro	Corrida A	Corrida B
periodSeconds	2	5
failureThreshold	2	3
timeoutSeconds	1	1
Manifiesto	k8s/cotizacion-deployment.yaml	k8s/cotizacion-probe-corrida-b.yaml, aplicado con kubectl patch

10.1.11 Resultados obtenidos

La hipótesis se cumplió en las dos corridas. El canal de cotización sostuvo la carga durante los 2 min 33 s de cada corrida. Una réplica dejó de responder GET /health, Kubernetes la marcó Ready=false y el Service dejó de enviarle tráfico. Desde ese instante la réplica sana atendió todas las cotizaciones. Las 1.800 solicitudes de cada corrida respondieron 200, con cero errores HTTP.

El punto de sensibilidad se comportó como se esperaba: un probe más lento alarga el retiro y deja más tráfico dirigido a la réplica que ya falló el health check.

Métrica	Corrida A	Corrida B
Intervalo del probe (periodSeconds)	2	5
Umbral de fallas (failureThreshold)	2	3
Retiro esperado (orden de magnitud)	4 s	15 s
Tiempo medido hasta Ready=false	2,3 s	13,5 s
POST totales	1.800	1.800
Errores HTTP	0	0
POST a la réplica retirada durante la detección	13	77
POST a la réplica sana después del retiro	765 (100 %)	717 (100 %)
Reparto total por Pod (sana / retirada)	1.289 / 511	1.258 / 542
Latencia promedio	4,56 ms	3,95 ms
Throughput	11,78 trans/s	11,80 trans/s

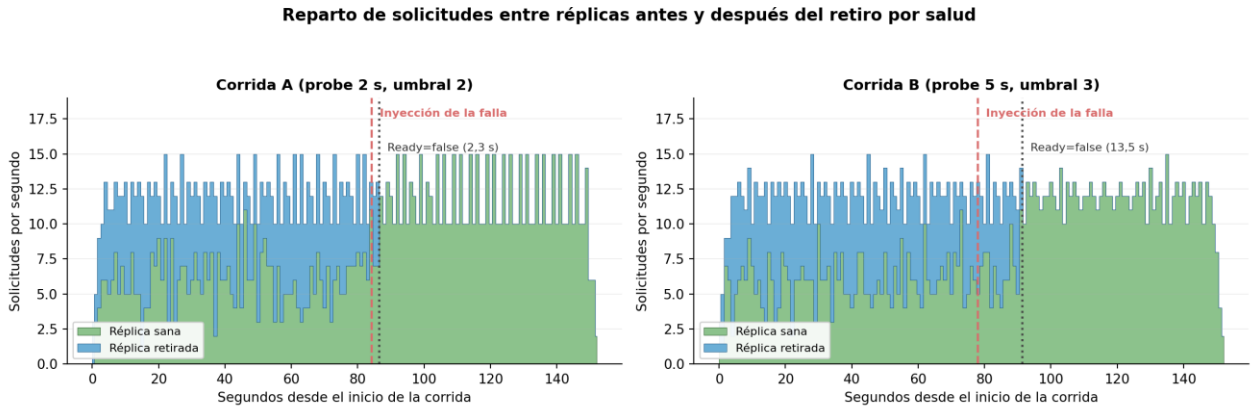


Ilustración 3. Reparto de solicitudes por segundo entre las dos réplicas, reconstruido desde la columna instancia de los archivos corrida-a.jtl y corrida-b.jtl. La línea roja marca la inyección de la falla y la línea punteada el instante en que el Pod queda Ready=false.

La gráfica muestra el corte con claridad. Antes de la inyección las dos réplicas reparten la carga. Dentro de la ventana de detección la réplica marcada sigue recibiendo solicitudes, y desde el instante Ready=false toda la carga la sostiene la réplica sana hasta el final de la corrida. En la corrida A esa ventana dura 2,3 s y en la corrida B dura 13,5 s.

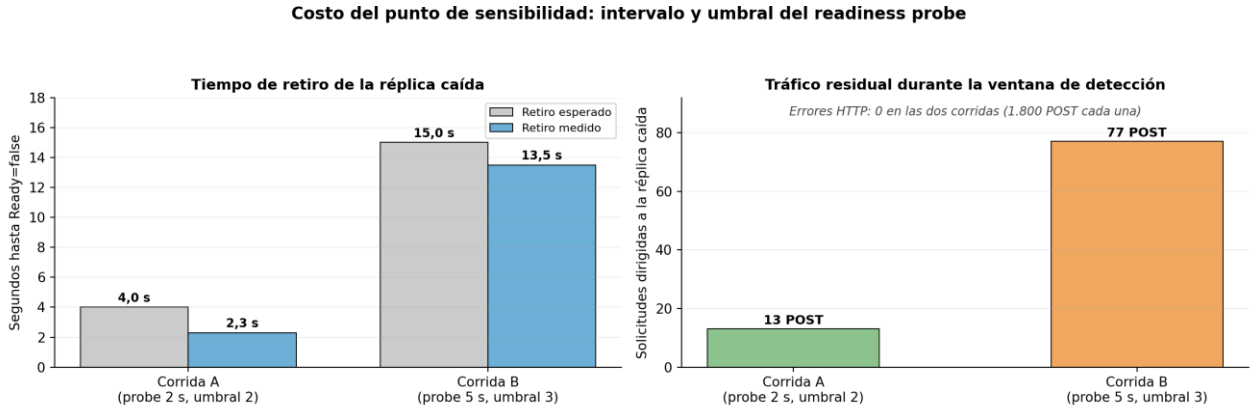


Ilustración 4. Costo del punto de sensibilidad. A la izquierda, el retiro esperado frente al retiro medido en cada corrida. A la derecha, las solicitudes que alcanzaron la réplica caída durante la ventana de detección.

Las 13 y 77 solicitudes dirigidas a la réplica retirada respondieron 200: el proceso seguía vivo y únicamente /health devolvía 503. El experimento mide el retiro por salud, y el campo instancia de las respuestas queda con un solo valor en cuanto el Pod sale del Service.

Marcas de tiempo de la inyección. Corrida A: instante 2026-09-12T03:05:15.902121Z sobre el Pod cotizacion-ccbbc8466-854t5, con Ready=false en 2,3 s y el Service reducido a un endpoint (10.244.0.3:8000). Corrida B: instante 2026-09-12T04:05:17.532236Z sobre cotizacion-9c8d7fd6d-b8znp, con Ready=false en 13,5 s y el Service en 10.244.0.6:8000. Las dos corridas se ejecutaron el 11 de septiembre de 2026 en horario de Colombia, la A cerca de las 22:03 y la B cerca de las 23:03.

10.1.12 Análisis de los resultados

La hipótesis se confirmó en A y en B. Antes de la falla las dos réplicas aparecen en el campo instancia de las respuestas. Tras el POST a /experimentos/falla-salud sobre un solo Pod, ese Pod queda Ready=false y sigue existiendo. El Service deja de listarlo y queda con un endpoint. JMeter sigue recibiendo cotizaciones 200 por la réplica sana.

La incertidumbre media declarada en la hipótesis se reduce así: con este diseño el cliente conserva respuestas 200 durante la conmutación mientras la réplica siga procesando POST /cotizaciones. El costo real de un probe lento es el tiempo adicional enviando carga a un nodo ya declarado no saludable.

Decisiones de arquitectura que favorecieron el resultado

- **Redundancia N+1 activo-activo.** Dos réplicas de Cotización atienden en paralelo. Al retirar una, la otra sostiene el flujo sin intervención manual. El estilo de microservicios por capacidad de negocio permite que una instancia falle sin tumbar el servicio.

- **Ping/Echo en el monitor de salud.** El readiness probe de Kubernetes sondea /health y el API Gateway solo enruta al Service. El punto de sensibilidad queda concentrado en un único mecanismo medible.
- **El Service solo lista Pods Ready.** Cuando kubelet marca Ready=false, Kubernetes retira el endpoint y el balanceo se actualiza solo. nginx conserva su configuración apuntando al nombre DNS del Service.
- **Readiness sin liveness.** Un liveness habría matado y recreado el contenedor, mezclando el retiro por salud con el self-healing. La medición aísla ASR-07: continuidad ante instancia no lista.
- **Falla inyectada en /health.** El Pod sigue vivo durante toda la corrida, de modo que lo medido es el monitor de salud y no el programador de Kubernetes.

La corrida A, con probe de 2 s y umbral de 2 fallas, es la configuración que conviene al flujo de cotización: retira en el orden de 2 a 4 s y deja tráfico residual mínimo. La corrida B confirma el mismo diseño y cuantifica el precio de relajar el umbral: cerca de 14 s y 77 solicitudes dirigidas al nodo enfermo. La corrida A queda como configuración de referencia del modelo de despliegue 2.0.

10.1.13 Evidencias del experimento 1

Las evidencias están en el repositorio MISOG6ProyectoFinal/solventa, rama main, carpeta experimentation/Experiment1.

Artefacto	Contenido
resultados/corrida-a.jtl	Cada POST de la corrida A con timestamp, código HTTP, éxito y el campo instancia. Es la fuente de las ilustraciones 3 y 4.
resultados/corrida-b.jtl	El mismo detalle para la corrida B.
resultados/corrida-a.log	Log de JMeter de la corrida A: 1.800 samples, 0 % de error, 11,7 req/s.
resultados/corrida-b.log	Log de JMeter de la corrida B: 1.800 samples, 0 % de error, 11,8 req/s.
resultados/corrida-a/index.html	Dashboard HTML de JMeter de la corrida A, agrupado por instancia.
resultados/corrida-b/index.html	Dashboard HTML de JMeter de la corrida B, agrupado por instancia.
scripts/inyectar_falla.py	Inyecta POST /experimentos/falla-salud dentro de un Pod, imprime el instante UTC y espera Ready=false.
scripts/levantar_k8s.py	Levanta el clúster y aplica los manifiestos del namespace solventa.
k8s/cotizacion-deployment.yaml	Deployment con dos réplicas y el probe de la corrida A.
k8s/cotizacion-probe-corrida-b.yaml	Parche del probe de la corrida B.
jmeter/cotizaciones.jmx	Plan de carga contra el gateway.

La lectura del .jtl sostiene el resultado: el campo instancia muestra dos Pods antes de la falla y uno solo después del retiro, con success=true y responseCode=200 en toda la serie. Los gráficos Over Time del dashboard de JMeter agregan en ventanas de 60 s, de modo que las ilustraciones 3 y 4 se construyen directamente desde el .jtl con resolución de un segundo.

10.2 Experimento 2 — Absorción de una avalancha de eventos paramétricos con cola de eventos y workers

10.2.1 Definición del experimento

Título del experimento	Absorción de una avalancha de eventos paramétricos con cola de eventos y workers (Competing Consumers)
Propósito del experimento	Validar que, ante una llegada masiva y simultánea de eventos paramétricos, la arquitectura orientada a eventos encola cada evento, los workers lo consumen con contrapresión y lo liquidan de forma idempotente, con cero pérdidas y con la cotización en línea intacta. El foco es la lógica de negocio del siniestro paramétrico bajo el pico.

Resultados esperados	• Todos los eventos publicados quedan encolados: publicados = procesados + pendientes en cola + DLQ, con cero eventos perdidos. • Cada evento se liquida una sola vez pese a reintentos y reentregas: cero liquidaciones duplicadas (idempotencia). • Al aumentar el número de workers, el tiempo de drenado de la cola baja de forma proporcional (escalamiento horizontal del consumo). • Durante el pico, la cotización en línea conserva su latencia. • La medición se ejecuta a escala reducida y se extrapola al objetivo de 1.000.000 de eventos en 10 minutos con capacity planning.
Elementos de arquitectura involucrados	ASR asociado: ASR-06 - Absorción de un evento paramétrico masivo (protege además ASR-01 al conservar la latencia de la cotización en línea). Elementos: Endpoint de ingesta (productor), cola de eventos con DLQ, y Workers de Siniestro Paramétrico como consumidores en competencia. Vista y modelo: Vista funcional - Modelo de componentes (cola de eventos y workers); Vista de información (idempotencia, DLQ y EventoParametrico). Punto de sensibilidad: número de workers concurrentes y la clave de idempotencia que resuelve el doble procesamiento ante reentregas.
Esfuerzo estimado	48 horas/hombre: 4 integrantes, 12 horas por integrante.

10.2.2 Hipótesis de diseño

Punto de sensibilidad	**Validar la profundidad de cola, el número de workers concurrentes (competing consumers) y la clave de idempotencia usada para procesar cada evento paramétrico una sola vez ante reentregas de la cola.**
Historia de arquitectura asociada	ASR-06: Absorción de un evento paramétrico masivo Como equipo de operaciones y siniestros, cuando un evento climático dispara de forma simultánea las pólizas paramétricas de una región, dado que cada evento debe evaluarse y pagarse sin intervención humana, quiero que la plataforma procese 1.000.000 de eventos en 10 minutos, esto debe ocurrir cada vez que se active un evento externo, para que el pago automático llegue al asegurado en el momento en que lo necesita.
Nivel de incertidumbre	Medio-Alto. Encolar desacopla la ingesta del procesamiento; el experimento mide cuántos workers drenan el pico dentro del objetivo y confirma que la clave de idempotencia sostiene cero pagos duplicados bajo reentregas masivas.

10.2.3 Estilos de arquitectura asociados al experimento

Estilos de Arquitectura asociados al experimento	**Análisis (Atributos de calidad que favorece y desfavorece)**
Orientado a eventos + Microservicios por capacidad de negocio	Favorece: • Escalabilidad: los workers se agregan de forma horizontal para drenar la cola. • Disponibilidad: la cola absorbe el pico y desacopla la ingesta del procesamiento. • Resiliencia: los mensajes irrecuperables se aíslan en la DLQ y el resto sigue fluyendo. Desfavorece: • Consistencia inmediata: el procesamiento es asíncrono, con consistencia eventual. • Operabilidad y observabilidad: suma piezas por monitorear (cola, DLQ, workers).

10.2.4 Tácticas de arquitectura asociadas al experimento

Tácticas de Arquitectura asociadas al experimento	Descripción
Encolamiento y contrapresión (backpressure)	La cola retiene los eventos y regula el ritmo de consumo de los workers, de modo que el procesamiento y la memoria se mantienen dentro de su capacidad durante el pico.
Consumidores en competencia (Competing Consumers)	Varios workers consumen de la misma cola; cada uno toma el siguiente mensaje disponible y así el consumo escala en horizontal.
Idempotencia (Idempotent Receiver)	Cada evento lleva una clave de idempotencia, de modo que una reentrega reconoce el evento ya procesado y lo liquida una sola vez.
Aislamiento de fallas (Dead Letter Queue)	Un evento irrecuperable (envenenado) se deriva a la DLQ y los eventos válidos que vienen detrás siguen su curso.

10.2.5 Patrones de arquitectura asociados al experimento

Patrones de Arquitectura asociados al experimento	Descripción
Competing Consumers	Escala el consumo en horizontal: cada worker toma el siguiente mensaje de la cola y reparte la carga entre las réplicas.
Idempotent Receiver	Ante la semántica 'al menos una vez' de la cola, la clave de idempotencia asegura un único cobro y una única liquidación por evento.
Dead Letter Queue (DLQ)	Aísla los mensajes irrecuperables, de modo que el procesamiento de los eventos válidos continúa aunque llegue un evento mal formado.

10.2.6 Componentes involucrados en el experimento

Componente	Propósito y comportamiento esperado	Tecnología asociada
Endpoint de Ingesta / Productor de eventos	Recibe los eventos externos (clima/vuelos) y los publica en la cola; el procesamiento pesado ocurre fuera de línea y la venta conserva su latencia.	Python 3 + FastAPI
Cola de Eventos (con DLQ)	Encola los eventos del pico, regula el consumo por long polling y deriva a la DLQ los eventos irrecuperables.	Amazon SQS
Workers de Siniestro Paramétrico (N réplicas)	Consumen de la cola en competencia, evalúan el disparo del paramétrico y liquidan de forma idempotente.	Python 3

10.2.7 Conectores involucrados en el experimento

Conector	Comportamiento deseado en el experimento	Tecnología asociada
HTTP/HTTPS síncrono - cliente	JMeter publica la avalancha de eventos hacia el endpoint de ingesta durante todo el pico.	HTTP/HTTPS
Publicación a la cola	El productor encola cada evento (SendMessage) en la cola, desacoplando la ingesta del procesamiento.	HTTPS (API SQS / SDK)
Consumo desde la cola	Cada worker toma el siguiente lote de mensajes (ReceiveMessage con long polling) en competencia con los demás y lo borra (DeleteMessage) solo tras liquidar.	HTTPS (API SQS / SDK)

10.2.8 Tecnología asociada con el experimento

Tecnología asociada con el experimento (Desarrollo, infraestructura, almacenamiento)	Justificación
Lenguajes de programación	Python 3 para el endpoint de ingesta y los workers del siniestro paramétrico.
Plataforma de despliegue	AWS sobre capa gratuita o créditos académicos; medición a escala reducida y extrapolación por capacity planning.
Contenedores	Docker y Docker Compose para levantar el productor y las N réplicas de workers de forma repetible y escalar el consumo con --scale; la cola SQS es un servicio gestionado y corre fuera de los contenedores.
Mensajería / Cola de eventos	Amazon SQS: cola gestionada de AWS con DLQ nativa y consumidores en competencia, disponible en capa gratuita y coherente con la nube AWS del proyecto. La arquitectura deja abierto el producto de mensajería, así que se adopta el servicio nativo de AWS.
Herramientas de análisis	JMeter y logs con marcas de tiempo para contar publicados, procesados, duplicados y mensajes en DLQ.
Frameworks de desarrollo	FastAPI para el endpoint de ingesta de eventos.

10.2.9 Distribución de actividades por integrante

Integrante	Tareas a realizar	Esfuerzo estimado
Nicolás	Implementar el endpoint de ingesta (FastAPI) y los workers de siniestro paramétrico con clave de idempotencia.	12 horas
Daniel	Configurar la cola de eventos (Amazon SQS) con long polling, visibilidad de mensaje y DLQ.	12 horas
Jerson	Preparar Docker Compose (productor y N workers), crear la cola SQS con su DLQ, desplegar en AWS y habilitar el escalado de workers.	12 horas
Jonatan	Preparar JMeter, ejecutar la avalancha de eventos y consolidar métricas (cero pérdidas, cero duplicados, drenado de cola).	12 horas

10.2.10 Ejecución del experimento

El productor está en FastAPI (app/main.py) y expone POST /eventos-parametricos. Recibe la póliza, el tipo de evento y los datos técnicos, genera la clave de idempotencia cuando el cliente la omite (IDEMP-{poliza_id}-{evento_tipo}-{uuid8}), publica el mensaje en la cola con esa clave como atributo y responde HTTP 202 Accepted. El productor deja la regla de negocio al worker: encola y devuelve el control, de modo que la avalancha conserva el presupuesto de latencia de la cotización en línea (ASR-01).

Los workers (app/worker.py) hacen long polling contra la cola con WaitTimeSeconds=10 y MaxNumberOfMessages=10, y corren en réplicas que compiten por los mensajes disponibles. Antes de liquidar, cada worker consulta registro_idempotencia por la clave del mensaje. Cuando la clave ya existe, el worker descarta el mensaje como pago doble evitado. Cuando la clave es nueva, evalúa la regla del siniestro paramétrico, inserta el registro en siniestros_liquidados y en registro_idempotencia dentro de una sola transacción, y solo entonces borra el mensaje de la cola. Si la transacción falla se ejecuta rollback y el mensaje permanece en la cola hasta que vence el Visibility Timeout.

Los mensajes marcados con ERROR_FORZADO en datos_evento hacen fallar al worker de forma intencional. La cola los reintenta hasta agotar maxReceiveCount = 3 y los mueve a eventos-parametricos-dlq, mientras los eventos válidos siguen drenándose.

Entorno de ejecución

Servicio	Rol en el experimento
Orquestación	Docker Compose sobre un nodo local (MacBook Pro con chip Apple M4 Pro, macOS con Docker Desktop).
api	Productor FastAPI. Expone POST /eventos-parametricos en el puerto 8000.
sqs-local	ElasticMQ como clon local de Amazon SQS, con la cola principal y su Dead Letter Queue.
db	PostgreSQL 15 con las tablas registro_idempotencia y siniestros_liquidados.
worker	Consumidor escalado horizontalmente con --scale worker=N.
Política de la cola	VisibilityTimeout de 10 s y RedrivePolicy con maxReceiveCount 3 hacia eventos-parametricos-dlq.

Plan de carga

Parámetro	Valor usado en las corridas
Destino	POST http://localhost:8000/eventos-parametricos
Cuerpo	Payload dinámico con funciones __Random() para poliza_id, vuelo y horas_retraso
Hilos (usuarios concurrentes)	50, con rampa de 5 s
Vueltas por hilo	20
Total de samples	1.000 solicitudes
Variable de escalado entre corridas	Réplicas de worker: --scale worker=2 en la corrida A y --scale worker=4 en la corrida B
Mensajes envenenados inyectados	5, con el atributo ERROR_FORZADO, para validar la DLQ
Plan	avalancha_solventa.jmx sobre Apache JMeter 5.6.3

10.2.11 Resultados obtenidos

La hipótesis se cumplió. El productor absorbió el pico completo de 1.000 solicitudes en 4 segundos de reloj de JMeter, con HTTP 202 Accepted en el 100 % de los casos, latencia promedio de 2 ms (mínimo 1 ms, máximo 24 ms, desviación estándar 1,08) y throughput sostenido de 203,0 solicitudes por segundo. Esa cifra corresponde a una sola réplica del productor en el nodo local y se repitió igual en las dos corridas, porque la ingesta es independiente del número de workers que consumen la cola.

Del lado del consumo se ejecutaron dos corridas variando únicamente el número de réplicas de worker, para observar el escalamiento horizontal del patrón Competing Consumers con el productor y el plan de JMeter intactos.

Métrica	Corrida A (2 workers)	Corrida B (4 workers)
POST totales a la API	1.000	1.000
Errores HTTP devueltos al cliente	0 (0 %)	0 (0 %)
Latencia promedio del POST	2 ms	2 ms
Latencia mínima / máxima	1 ms / 24 ms	1 ms / 24 ms
Throughput de ingesta	203,0 trans/s	203,0 trans/s
Mensajes liquidados sin pérdida	1.000 / 1.000	1.000 / 1.000
Liquidaciones duplicadas	0	0

Métrica	Corrida A (2 workers)	Corrida B (4 workers)
Tiempo de drenado de la cola	Cerca de 255 s (4,2 min)	Cerca de 128 s (2,1 min)
Mensajes envenenados aislados en la DLQ	5 / 5	5 / 5

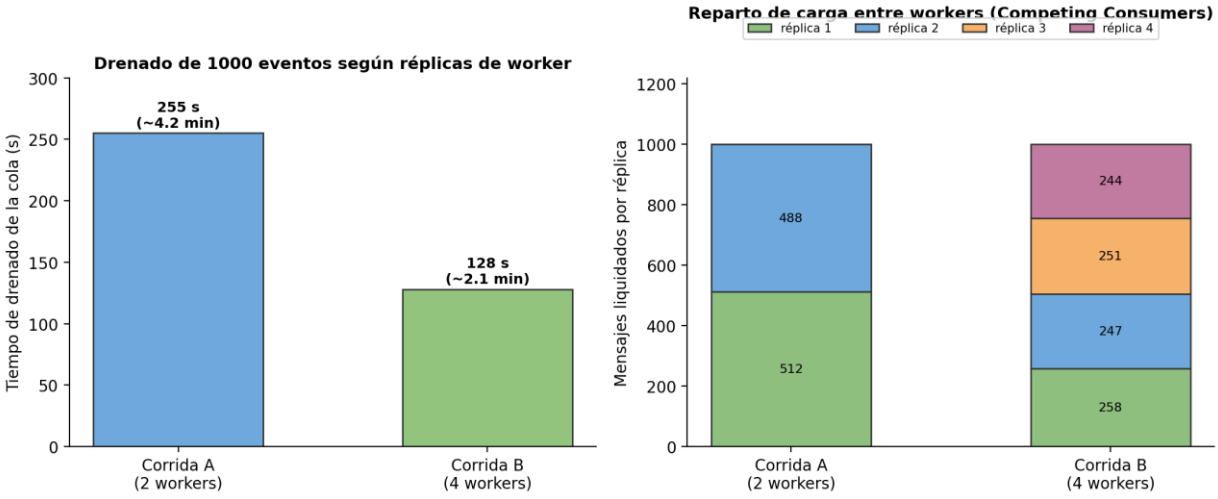


Ilustración 5. Tiempo de drenado y reparto de carga entre workers. Corrida A con 2 réplicas frente a corrida B con 4 réplicas.

Las dos corridas cerraron sin pérdida de mensajes y sin registros duplicados en PostgreSQL. La tabla registro_idempotencia quedó con exactamente 1.000 filas, una por idempotency_key, lo que comprueba que la validación dentro de la transacción sostiene una sola liquidación por evento incluso con réplicas compitiendo por el mismo lote de mensajes. Al pasar de 2 a 4 réplicas el drenado bajó de forma aproximadamente proporcional, de 255 s a 128 s, y el reparto quedó en 512 y 488 mensajes por réplica en la corrida A, y en 258, 247, 251 y 244 en la corrida B. Los 5 mensajes marcados con ERROR_FORZADO agotaron sus 3 reintentos y pasaron a la Dead Letter Queue en ambas corridas, con los mensajes válidos siguiendo su curso.

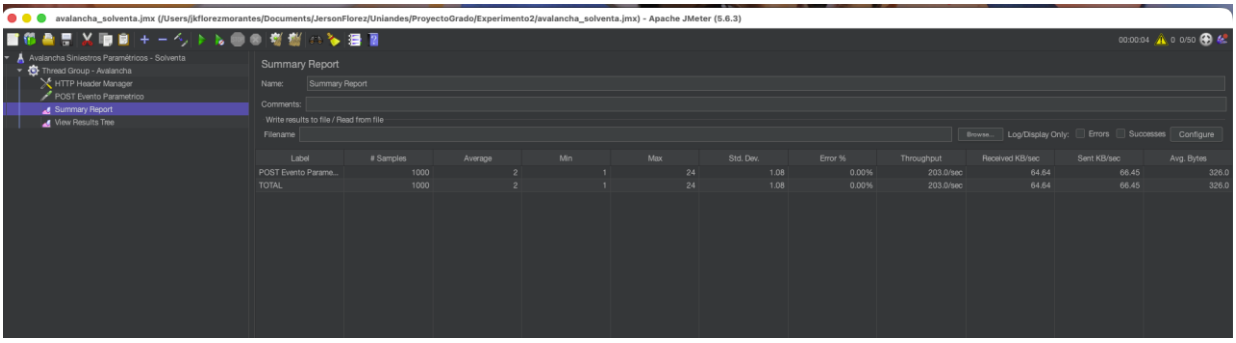


Ilustración 6. Summary Report de JMeter: 1.000 muestras, 0,00 % de error y 203,0 solicitudes por segundo en la ingesta del productor.

10.2.12 Extrapolación y planeación de capacidad

El objetivo del ASR-06 es absorber 1.000.000 de eventos en 10 minutos, cerca de 1.666,7 solicitudes por segundo sostenidas. Una réplica del productor sostuvo 203,0 TPS con 2 ms de latencia promedio, de modo que el factor de escalamiento requerido es cercano a 8,2. Detrás de un API Gateway o balanceador, 8 réplicas entregan una capacidad agregada estimada de 1.624 TPS y 10 réplicas llegan a 2.030 TPS, con un colchón cercano a 360 TPS para absorber varianza y picos dentro del pico.

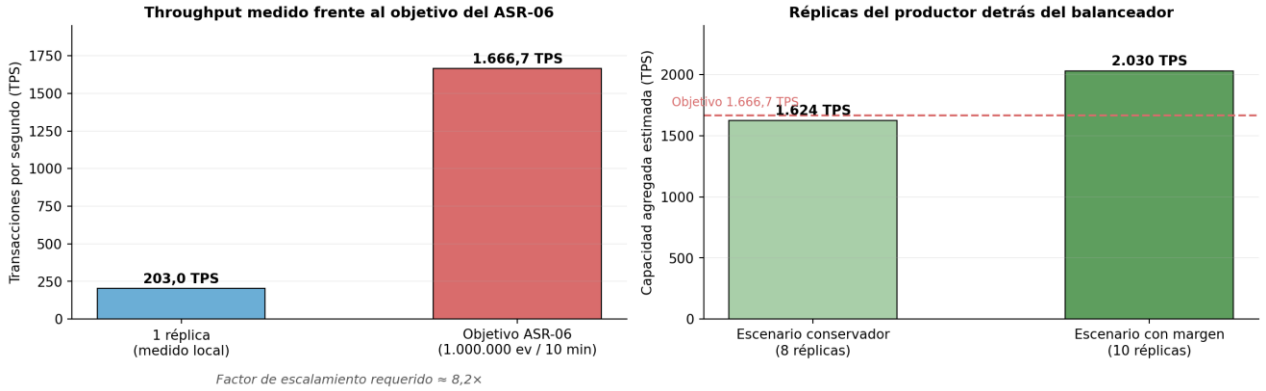


Ilustración 7. Extrapolación de capacidad del productor: throughput medido frente al objetivo del ASR-06 y réplicas necesarias detrás del balanceador.

El lado del consumo se lee con más cuidado. Las corridas A y B muestran que el drenado escala de forma aproximadamente proporcional al número de workers, y ese es el patrón que se lleva a producción. La cifra absoluta de workers se recalibra en la nube, porque el worker de la prueba simula la evaluación del siniestro paramétrico con una espera fija de 500 ms (time.sleep(0.5) en worker.py), un valor pensado para hacer visible el reparto de carga entre réplicas. Cuando la evaluación real se resuelva en el orden de decenas de milisegundos, que es lo razonable para una regla que compara un umbral contra un dato ya recibido de clima o vuelos, el mismo patrón de escalamiento ubica el número de workers entre 10 y 15 réplicas. Esa cifra queda como hipótesis de diseño para la siguiente iteración, y se fija como capacidad instalada al perfilar el tiempo real de evaluación bajo carga en la nube.

10.2.13 Análisis de los resultados

La inyección evidenció el éxito del desacoplamiento. El alto volumen de escrituras se manejó sin deadlocks ni condiciones de carrera, apoyado en la capacidad de cómputo y la lectura rápida en disco del nodo de ejecución. El comportamiento de los mensajes envenenados confirmó que aislar los fallos en la DLQ preserva la salud del flujo completo, sosteniendo el ASR-06 y conservando la latencia que protege el ASR-01.

Decisiones de arquitectura que favorecieron el resultado

- **Encolamiento y contrapresión.** La cola retiene los eventos y regula el ritmo de consumo de los workers, de modo que el procesamiento y la memoria se mantienen dentro de su capacidad durante el pico, con ese ritmo oculto al cliente que reporta el evento.
- **Competing Consumers.** Varios workers consumen de la misma cola y cada uno toma el siguiente mensaje disponible. El consumo escala en horizontal al agregar réplicas: el drenado bajó de 255 s a 128 s al pasar de 2 a 4.
- **Idempotent Receiver.** La clave de idempotencia, validada dentro de la misma transacción que la liquidación, sostiene una sola liquidación por evento ante reentregas y consumo concurrente entre réplicas.
- **Dead Letter Queue.** Un evento irrecuperable se aísla tras agotar sus reintentos, de modo que los eventos válidos que vienen detrás siguen drenándose.

La incertidumbre media-alta declarada en la hipótesis se reduce así: duplicar las réplicas de worker reduce el tiempo de drenado de forma aproximadamente proporcional, y el costo de escalar el consumo es cómputo adicional en contenedores worker, con el contrato del productor y el cliente intactos. El punto sensible real es el tiempo que tarda el negocio en ver los eventos liquidados, que queda como parámetro de escalado horizontal.

10.2.14 Evidencias del experimento 2

Las evidencias están en el repositorio MISOG6ProyectoFinal/solventa, rama main, carpeta experimentation/Experiment2.

Artefacto	Contenido
avalancha_solventa.jmx	Plan de JMeter que inyecta la avalancha sobre el endpoint de ingesta.
docker-compose.yml	Orquestación de los servicios api, sqs-local, db y worker, escalable con --scale.
setup_sqs.sh	Creación de la cola principal y la DLQ, con VisibilityTimeout 10 s y maxReceiveCount 3.

Artefacto	Contenido
app/main.py	Productor FastAPI: encola el evento con la clave de idempotencia y responde 202 Accepted.
app/worker.py	Consumidor: long polling, validación de idempotencia, liquidación transaccional y manejo de fallas.
app/models.py	Modelos RegistroIdempotencia y SiniestroLiquidado sobre PostgreSQL.
docker logs experimento2-worker-*	Traza de la validación de la clave de idempotencia y de los tres reintentos previos a la DLQ.

La tabla registro_idempotencia es la evidencia de que cada evento se liquidó una sola vez: cierra con 1.000 filas, una por idempotency_key, con dos y luego cuatro réplicas compitiendo por los mismos lotes. Los logs de worker muestran, para los 5 mensajes ERROR_FORZADO, tres intentos fallidos consecutivos antes de que la cola los moviera a eventos-parametricos-dlq.

11. Evolución de la arquitectura

Esta sección recoge, en orden, cada mejora que entró a la arquitectura desde la versión 1.0 de la visión hasta la versión 2.0 de los modelos funcional y de despliegue. Cada fila declara su origen, el ASR que sostiene y el modelo donde quedó dibujada.

11.1 Registro ordenado de mejoras

#	Hito	Mejora incorporada	ASR	Modelo
1	Visión 1.0	Modelo funcional en cinco capas: clientes, exposición por canal, lógica de negocio en microservicios por capacidad, integración y mensajería, y persistencia por capacidad.	ASR-01 a ASR-14	VC-003 1.0
2	Visión 1.0	Despliegue en nube multizona, con región primaria activo-activo en dos zonas y región secundaria en espera para el failover.	ASR-07, ASR-08, ASR-09	VC-004 1.0
3	Hoja de trabajo de experimentos	Definición del Experimento 1 sobre la continuidad de la cotización y del Experimento 2 sobre la absorción del evento paramétrico masivo, con punto de sensibilidad y esfuerzo por integrante.	ASR-06, ASR-07	Insumo de diseño
4	Detalle de arquitectura	Monitor de Salud y Retiro en la capa de exposición: sondea los microservicios y retira las instancias degradadas del enrutamiento.	ASR-07, ASR-08	VC-003
5	Detalle de arquitectura	Validador de Consenso sobre Cotización redundante: compara los resultados de las réplicas con una ventana acotada en tiempo y emite la respuesta mayoritaria.	ASR-01, ASR-05, ASR-07	VC-003
6	Detalle de arquitectura	Circuit Breaker Global sobre los adaptadores externos, con la caché de perfil y cotización como fallback de último dato bueno conocido.	ASR-01, ASR-02, ASR-03, ASR-10	VC-003
7	Detalle de arquitectura	Workers de Absorción de Picos que consumen del Bus de Eventos y sacan el procesamiento masivo de los hilos síncronos.	ASR-06	VC-003
8	Detalle de arquitectura	Réplicas Síncronas Multi-AZ para Cotización y Catálogo y para Pólizas y Suscripción en la capa de persistencia.	ASR-08, ASR-09	VC-003

#	Hito	Mejora incorporada	ASR	Modelo
9	Experimento 1 ejecutado, 11 de septiembre de 2026	Readiness probe con periodSeconds 2 y failureThreshold 2 como configuración de referencia: retiro medido en 2,3 s con cero errores HTTP.	ASR-07	VC-004 2.0
10	Experimento 1 ejecutado, 11 de septiembre de 2026	Health Monitor como artefacto propio del borde de red, con heartbeat por debajo de 500 ms hacia cada nodo de las dos zonas.	ASR-07, ASR-08	VC-004 2.0
11	Experimento 2 ejecutado, septiembre de 2026	Idempotency Key Validator como componente propio que valida la clave única por evento antes de que Siniestro Paramétrico liquide.	ASR-06	VC-003 2.0
12	Experimento 2 ejecutado, septiembre de 2026	Dead Letter Queue separada del Bus de Eventos como componente propio, con su política de tres reintentos en el conector.	ASR-06	VC-003 2.0
13	Experimento 2 ejecutado, septiembre de 2026	Nodo «Workers Siniestro Paramétrico» con N réplicas en Competing Consumers dentro de cada zona de disponibilidad.	ASR-06	VC-004 2.0
14	Experimento 2 ejecutado, septiembre de 2026	Auto-Scaling Group (KEDA o AWS ASG) que ajusta las réplicas de worker por la métrica ApproximateNumberOfMessagesVisible de la cola.	ASR-05, ASR-06	VC-004 2.0
15	Experimento 2 ejecutado, septiembre de 2026	Connection Proxy (PgBouncer o AWS RDS Proxy) entre los workers y la base relacional de cada zona, para agrupar las conexiones de escritura.	ASR-06	VC-004 2.0
16	Modelos 2.0	Conectores declarados con notación UML 2.0: «route», «call», «publish», «subscribe», «replicate», «persist», agregación del Circuit Breaker Global y heartbeat del monitor de salud.	Todos	VC-003 2.0
17	Modelos 2.0	Tipificación de nodos con «environment», «execution environment» y «node», y del software desplegado con «artifact», más los estereotipos «Master», «Réplica síncrona» y «Réplica asíncrona» en las bases de datos.	Todos	VC-004 2.0

11.2 Cambios validados en el modelo de componentes (VC-003 2.0)

Cambio	Qué resuelve	Evidencia que lo respalda
Monitor de Salud y Retiro con heartbeat hacia Cotización y Rating y Siniestros	Detecta la instancia degradada y la retira del enrutamiento sin esperar el reporte del cliente.	Experimento 1: retiro en 2,3 s con probe de 2 s y umbral de 2, y cero errores HTTP en 1.800 solicitudes.
Validador de Consenso sobre Cotización redundante	Compara los resultados de las réplicas y emite la respuesta mayoritaria dentro de una ventana acotada en tiempo.	Detalle de arquitectura, sección 9.5.1. El Experimento 1 confirmó que las réplicas paralelas sostienen el flujo.
Circuit Breaker Global agregando cada adaptador externo	Corta la llamada lenta en el origen y habilita el fallback desde la caché de perfil y cotización.	Detalle de arquitectura, sección 9.5.1, con timeouts de 700 ms para Open Finance y 3000 ms como máximo absoluto.
Workers de Absorción de Picos sobre el Bus de Eventos	Saca el procesamiento masivo de los hilos síncronos y protege el presupuesto de latencia de la cotización en línea.	Experimento 2: 1.000 eventos absorbidos en 4 s con 202 Accepted en el 100 % de los casos y 203,0 TPS de ingesta.

Cambio	Qué resuelve	Evidencia que lo respalda
Idempotency Key Validator como componente propio	Sostiene una sola liquidación por evento ante reentregas de la cola y consumo concurrente entre réplicas.	Experimento 2: 1.000 filas en registro_idempotencia, una por idempotency_key, y cero liquidaciones duplicadas en las dos corridas.
Dead Letter Queue separada del Bus de Eventos	Aísla el evento irrecuperable tras tres reintentos y deja que los eventos válidos sigan drenándose.	Experimento 2: los 5 mensajes con ERROR_FORZADO pasaron a eventos-parametricos-dlq en ambas corridas, con el pico drenado completo.
Réplicas Síncronas Multi-AZ en Cotización y Catálogo y en Pólizas y Suscripción	Conserva en dos ubicaciones físicas toda transacción confirmada al cliente y permite promover la réplica sin intervención manual.	Detalle de arquitectura, sección 9.5.1, alineado con el RPO de 30 s del ASR-09 y el RTO de 10 min del ASR-08.
Conectores UML 2.0 declarados en el diagrama	Hace explícito el tipo de acoplamiento de cada relación: enrutamiento, invocación síncrona, mensajería asíncrona, replicación, persistencia, agregación y sondeo de salud.	Modelo de componentes 2.0, convención del diagrama.

11.3 Cambios validados en el modelo de despliegue (VC-004 2.0)

Cambio	Qué resuelve	Evidencia que lo respalda
Health Monitor como artefacto del borde de red, con heartbeat por debajo de 500 ms	Concentra la detección de fallas en un mecanismo propio y medible, con la ruta de sondeo visible en el diagrama.	Experimento 1: el par intervalo y umbral del sondeo determina el tiempo de retiro, medido en 2,3 s y 13,5 s.
Nodo «Workers Siniestro Paramétrico» con N réplicas en cada zona	Asigna el consumo de la cola a un nodo propio y deja el escalamiento horizontal como decisión de despliegue.	Experimento 2: el drenado bajó de 255 s a 128 s al pasar de 2 a 4 réplicas, con reparto parejo entre ellas.
Auto-Scaling Group por profundidad de cola	Ajusta las réplicas de worker con la métrica ApproximateNumberOfMessagesVisible en lugar de dejar el número fijo.	Experimento 2: la extrapolación ubica el productor entre 8 y 10 réplicas para el objetivo del ASR-06.
Connection Proxy entre los workers y la base relacional de cada zona	Agrupa las conexiones de escritura de la clave de idempotencia y sostiene la concurrencia cuando el número de réplicas crece.	Experimento 2: los workers compiten por escribir en registro_idempotencia dentro de la misma transacción de liquidación.
Tipificación de nodos y artefactos con estereotipos UML 2.0	Distingue el ambiente, el entorno de ejecución, el nodo y el artefacto desplegado, y marca el rol de cada base de datos.	Modelo de despliegue 2.0, convención del diagrama.
Región secundaria con clúster pasivo y réplica asíncrona declarada	Deja explícito el destino del failover de región con RTO de 5 minutos y RPO de 30 segundos.	Modelo de despliegue 2.0, alineado con los escenarios EC008 y EC009.

12. Plan de trabajo

El plan cubre siete semanas en tres sprints, con 146 puntos de historia repartidos en 111 funcionales y 35 de arquitectura. Cada historia y cada ítem de arquitectura queda trazado a su tarjeta de Jira.

12.1 Resumen por sprint

Sprint	Duración	PH funcionales	PH arquitectura	PH totales
Sprint 1	2 semanas	28	10	38
Sprint 2	2 semanas	36	10	46
Sprint 3	3 semanas	47	15	62
Total	7 semanas	111	35	146

12.2 Distribución de carga por responsable

Responsable	PH funcionales	PH arquitectura	PH totales
Nicolás Cárdenas	29	5	34
Jonatan Esmits Hernández Rubio	26	10	36
Daniel Serna Osorio	28	10	38
Jerson A Florez Rojas	28	10	38

12.3 Sprint 1

2 semanas. Funcional: 28 PH. Arquitectura: 10 PH. Total: 38 PH.

Historias de usuario funcionales

Historia / Jira	PH	Responsable
KAN-15 HU020: Captura de fotografías y grabación de video de daños desde la cámara	8	Nicolás Cárdenas
KAN-25 HU030: Cotización de un seguro desde la app	5	Daniel Serna Osorio
KAN-33 HU001: Diligenciar formulario dinámico de cotización por ramo	5	Jerson A Florez Rojas
KAN-40 HU008: Alta y aprovisionamiento del socio con contrato de API	5	Jonatan Esmits Hernández Rubio
KAN-42 HU010: Configuración de ramos y coberturas habilitados por socio	5	Jonatan Esmits Hernández Rubio
Total funcional Sprint 1	28	

Ítems de arquitectura asociados

ASR / Jira	PH	Responsable
ARQ-1 ASR-01: Latencia de la cotización embebida	5	Jonatan Esmits Hernández Rubio
ARQ-3 ASR-03: Presupuesto de latencia por dependencia externa	5	Jonatan Esmits Hernández Rubio
Total arquitectura Sprint 1	10	

12.4 Sprint 2

2 semanas. Funcional: 36 PH. Arquitectura: 10 PH. Total: 46 PH.

Historias de usuario funcionales

Historia / Jira	PH	Responsable
KAN-18 HU023: Persistencia local del reporte en modo offline	8	Nicolás Cárdenas
KAN-26 HU031: Pago de una cotización vigente	5	Daniel Serna Osorio
KAN-27 HU032: Confirmación y visualización de la póliza	5	Daniel Serna Osorio
KAN-34 HU002: Capturar consentimiento digital para Open Finance y Open Data	5	Jerson A Florez Rojas
KAN-35 HU003: Visualizar el desglose de cotización en tiempo real	5	Jerson A Florez Rojas
KAN-46 HU014: API de cotización embebida	8	Jonatan Esmits Hernández Rubio
Total funcional Sprint 2	36	

Ítems de arquitectura asociados

ASR / Jira	PH	Responsable
ARQ-2 ASR-02: Latencia del perfilamiento en línea de vida hipotecario	5	Jerson A Florez Rojas
ARQ-15 ASR-10: Continuidad ante la degradación de un proveedor externo	5	Jerson A Florez Rojas
Total arquitectura Sprint 2	10	

12.5 Sprint 3

3 semanas. Funcional: 47 PH. Arquitectura: 15 PH. Total: 62 PH.

Historias de usuario funcionales

Historia / Jira	PH	Responsable
KAN-19 HU024: Sincronización automática en segundo plano al recuperar conexión	8	Nicolás Cárdenas
KAN-21 HU026: Solicitud de asistencia en sitio con un solo toque	5	Nicolás Cárdenas
KAN-30 HU035: Consulta de condiciones de renovación	3	Daniel Serna Osorio
KAN-31 HU036: Pago de renovación	5	Daniel Serna Osorio
KAN-32 HU037: Confirmación de la renovación	5	Daniel Serna Osorio
KAN-37 HU005: Consultar estado y detalles de una póliza emitida	3	Jerson A Florez Rojas
KAN-38 HU006: Registrar endoso (modificación) de póliza	5	Jerson A Florez Rojas
KAN-39 HU007: Procesar cancelación de póliza con recálculo	5	Jerson A Florez Rojas
KAN-47 HU015: API de emisión de póliza desde el canal del socio	5	Jonatan Esmits Hernández Rubio
KAN-48 HU016: API de consulta de estado de póliza y de siniestro	3	Jonatan Esmits Hernández Rubio
Total funcional Sprint 3	47	

Ítems de arquitectura asociados

ASR / Jira	PH	Responsable
ARQ-12 ASR-07: Disponibilidad de los flujos críticos	5	Daniel Serna Osorio
ARQ-13 ASR-08: Recuperación ante la caída de una zona	5	Daniel Serna Osorio

ASR / Jira	PH	Responsable
ARQ-14 ASR-09: Pérdida de datos ante la caída de una zona	5	Nicolás Cárdenas
Total arquitectura Sprint 3	15	

13. Documentación técnica del prototipo

Esta sección documenta el prototipo navegable de Solventa, en el portal web y en la aplicación móvil. El prototipo está publicado en https://film-proof-76716956.figma.site/. La portada abre tres entradas: Web App, Mobile App y Design System. Sirve para recorrer los flujos y ver el efecto de las simulaciones. Los clientes web y móvil se construirán en Angular. Este prototipo solo muestra las pantallas y las simulaciones. La sección 14 explica los recorridos paso a paso.

13.1 Organización del prototipo

El sitio es una sola página. Al elegir un canal, el prototipo cambia la pantalla sin abrir otra dirección. Las partes son estas:

Módulo	Qué hace en el prototipo
Portada	Muestra las tres entradas y pasa de una a otra en la misma página.
Portal web	Operación comercial, alta de socios y operaciones del canal embebido.
Aplicación móvil	Autoservicio del asegurado: inicio, pólizas, compra, renovación y siniestros.
Sistema de diseño	Colores, tipografía, componentes e íconos que usan el portal y la aplicación.
Idioma	Diccionario en español y en inglés. El idioma elegido queda guardado en el navegador.

En el portal web, Cotización reúne el formulario por ramo, el consentimiento y el cálculo. Consulta de pólizas reúne el detalle, el endoso y la cancelación. Socios e Integraciones reúne el alta del socio, la credencial y los ramos habilitados. Operaciones del canal recorre lo que el sistema del socio haría contra Solventa: cotizar, emitir y consultar.
La barra del portal tiene dos módulos: Operaciones y Pólizas, y Socios e Integraciones. Operaciones y Pólizas tiene dos pestañas: Cotización y Consulta de pólizas. En el detalle de un socio hay dos pestañas: la configuración de ramos y coberturas, y Operaciones del canal.
En la aplicación móvil, la barra inferior tiene cuatro destinos: Inicio, Pólizas, Siniestros y Comprar. Desde ahí se recorre la compra, la renovación, el siniestro y la asistencia. Arriba hay un control de demostración con dos posiciones: Demo: En linea y Demo: Sin conexion. Ese control lo cambia quien recorre el prototipo. No lee la red del equipo.
El sistema de diseño abre cuatro láminas: colores, tipografía, componentes e íconos. Esas piezas son las que ya se ven en el portal y en la aplicación.

13.2 Datos del prototipo

Los textos del prototipo están en español y en inglés. El español es el idioma con el que abre. La preferencia de idioma queda guardada en el navegador y es el único dato que sigue ahí después de recargar la página.
La cotización, la póliza creada, el socio dado de alta y el siniestro reportado viven en la memoria de la pestaña. Al recargar, esa sesión desaparece y el catálogo de demostración vuelve a cargarse desde el propio sitio.
El catálogo trae seis ramos: viaje, dispositivos, microseguro de vida, paramétrico, protección de pagos y vida hipotecario. Al cambiar el ramo, cambia el formulario del riesgo; los datos del cliente permanecen. Los estados de demostración son estos: póliza activa, cancelada o vencida; pago aprobado, pendiente o rechazado; credencial activa o revocada; contrato de API activo o suspendido.

13.3 Comportamiento simulado en web y en móvil

Cotización en el portal. El formulario revisa obligatorios, correo, teléfono y los números del ramo antes de calcular. Si el ramo exige consentimiento Open Finance / Open Data, el cálculo espera a que el código OTP quede validado. El prototipo registra el canal del código (SMS o correo), el alcance de lectura, la fecha y quién autorizó. Sin ese consentimiento, la cotización de ese ramo no se calcula.
Encima del cálculo está el selector Simulación de proveedores externos (demo). Cada modo cambia solo esa cotización:

Modo en pantalla	Efecto en la cotización
Proveedores responden con normalidad	Calcula la tarifa en el momento. El perfil de riesgo usa el puntaje 742 y la fecha de la sesión.
Proveedor lento · se usa la última información válida	Calcula la tarifa y la marca en modo degradado. El perfil usa el dato guardado: puntaje 705 y fecha 10 sep 2026 · caché.
Proveedor sin respuesta y sin información previa	No calcula la tarifa. Informa que un proveedor de información no respondió y deja el precio sin generar.

Consulta, endoso y cancelación usan pólizas de demostración. Si la póliza está cancelada o vencida, el endoso permanece bloqueado. La cancelación pide una causa, muestra el cálculo de la devolución y, al confirmar, deja la póliza en estado cancelada.

Alta de socio. El formulario pide nombre, identificador, tipo, país, correo técnico y al menos un alcance: cotización, emisión o consulta. Si el identificador ya existe, el prototipo no crea la credencial. Si el alta termina, muestra una sola vez el identificador de la credencial y el secreto, junto con la fecha, quién autorizó y el alcance. En el detalle se encienden ramos y coberturas. Operaciones del canal recorre cotizar, emitir y consultar. Si el contrato está suspendido, o si el alcance no incluye la acción, esa acción se detiene.

Compra en la aplicación móvil. Comprar muestra los productos habilitados para ese canal. La cotización enseña la prima, las coberturas y la vigencia antes del pago. El pago es simulado: se puede aprobar o rechazar. Solo un pago aprobado deja una póliza activa, con número, fecha de inicio, fecha de fin y coberturas.
Renovación. La oferta se abre en solo lectura: prima nueva, vigencia y coberturas. Verla deja la póliza vigente sin cambios. Si el pago de la renovación se rechaza, la póliza actual sigue igual. Si se aprueba, la confirmación muestra las nuevas fechas de vigencia.

Siniestro y asistencia. La captura acepta foto o video. Cada evidencia guarda fecha, hora y ubicación, y se puede repetir o eliminar antes de enviar. El prototipo admite hasta 10 evidencias; al llegar a 10, la siguiente no entra. Con Demo: Sin conexion, el reporte se guarda en el dispositivo y queda pendiente de sincronización. Al volver a Demo: En linea, el reporte se radica y muestra el número. La asistencia en sitio usa el modo en línea: toma la ubicación y muestra un tiempo estimado de llegada.

13.4 Cómo abrir el prototipo

Basta con abrir el enlace en el navegador.
https://film-proof-76716956.figma.site/
En la portada se elige Web App o Mobile App. El idioma se puede cambiar entre español e inglés, y esa elección permanece al recargar.
Al recorrerlo, tres límites definen lo que se puede esperar de la sesión:
1. Recargar la página borra la cotización, el socio y el siniestro creados en esa sesión. El idioma elegido permanece.
2. Demo: Sin conexion es el interruptor de la vista móvil. No apaga la red del equipo.
3. Los tres modos de proveedor cambian la cotización del portal web. No cambian la compra móvil ni el alta del socio.

14. Guía de usuario

Esta guía resume los recorridos principales de Solventa desde el punto de vista de quien usa la plataforma.

14.1 Canales y recorridos disponibles

Solventa tiene dos experiencias principales. El portal Web está pensado para asesores, operación y equipos de alianzas; la aplicación Mobile está pensada para el cliente asegurado. El canal embebido de los socios se representa desde Web mediante las operaciones que luego serían consumidas por API.

Canal	Recorrido	Historias de referencia	Sprint
Web	Cotización asistida	HU001 / KAN-33	Sprint 1

Web	Alta de socio y credenciales	HU008 / KAN-40	Sprint 1
Mobile	Evidencias de un siniestro	HU020 / KAN-15	Sprint 1
Mobile	Cotización desde la app	HU030 / KAN-25	Sprint 1
Mobile	Pago y emisión	HU031 / KAN-26 · HU032 / KAN-27	Sprint 2
Mobile	Consulta de oferta de renovación	HU035 / KAN-30	Sprint 3

Además de estos recorridos, los mockups cubren consulta de pólizas, endosos, cancelaciones, configuración de ramos por socio, emisión y consulta por canal embebido, operación offline, sincronización, asistencia en sitio y confirmación de renovación.

14.2 Portal Web: cotización y gestión de pólizas

Para crear una cotización asistida, el usuario entra a Operaciones y Pólizas → Cotización. El primer dato que define el formulario es el ramo; al cambiarlo, también cambian los campos del riesgo que deben diligenciarse. Los datos comunes del cliente permanecen y el sistema valida obligatorios, formatos y campos numéricos antes de dejar avanzar.

1. Seleccionar el ramo que se va a cotizar.
2. Diligenciar los datos del cliente y los datos propios del riesgo.
3. Corregir cualquier validación mostrada en pantalla. Si el flujo requiere consentimiento de Open Finance/Open Data, debe completarse antes de continuar.
4. Revisar la oferta generada, incluida la prima y las coberturas, antes de pasar al siguiente paso del proceso.

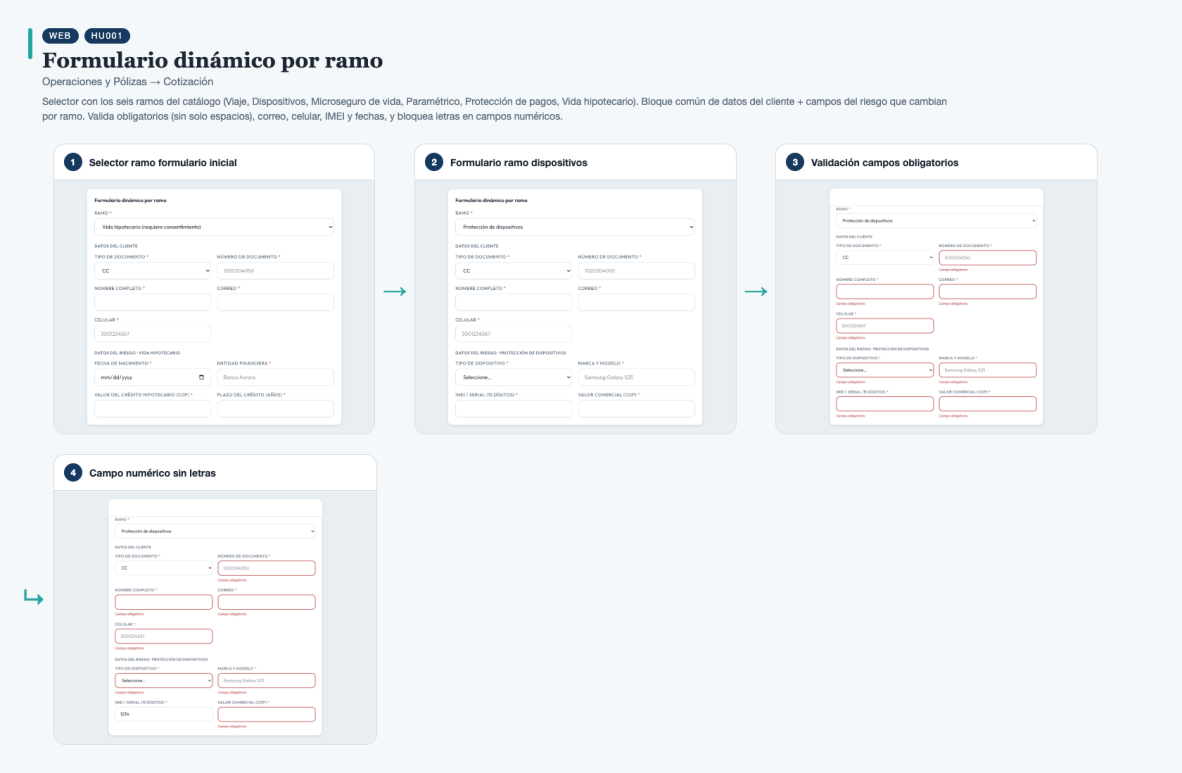


Ilustración 8. Flujo Web de cotización dinámica por ramo (HU001).

Para consultar una póliza, se usa Operaciones y Pólizas → Consulta de pólizas. La búsqueda puede hacerse por número de póliza o identificación y se puede filtrar por estado o socio de origen. Al abrir el detalle aparecen las secciones de asegurado, coberturas, pagos y siniestros. Desde ese mismo detalle se puede registrar un endoso o iniciar una cancelación. Los endosos quedan bloqueados si la póliza ya está cancelada o vencida; la cancelación exige una causa, muestra el cálculo de devolución y, una vez confirmada, deja la póliza en estado CANCELADA.

14.3 Portal Web: socios e integraciones

El alta de un socio se hace desde Socios e Integraciones → Nuevo socio. El formulario solicita nombre, identificador único, tipo de socio, país, correo técnico y el alcance inicial que se le va a habilitar.

1. Diligenciar los datos básicos y escoger los alcances permitidos: cotización, emisión y/o consulta.
2. Seleccionar Crear y aprovisionar.

3. Guardar el client_id y el secreto generado. El secreto se muestra una sola vez.
4. Verificar que el contrato de API quede activo y que la plataforma muestre fecha de alta, usuario que autorizó y alcance asignado.
5. Si el identificador ya existe, corregirlo antes de volver a intentar; el sistema no crea credenciales parciales para ese caso.

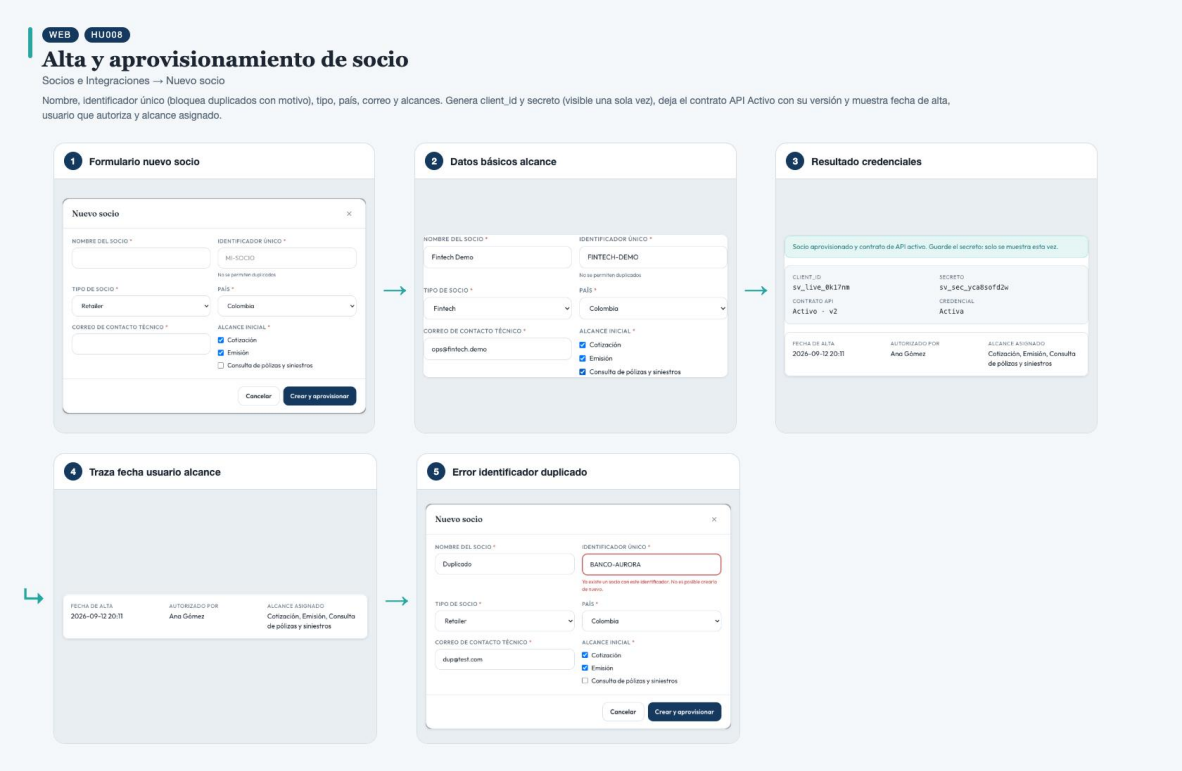


Ilustración 9. Alta y aprovisionamiento de un socio desde el portal Web (HU008).

Una vez creado el socio, desde su detalle se pueden definir ramos y coberturas habilitadas. El módulo Operaciones del canal permite recorrer las acciones que el socio consume desde su propio sistema: cotizar, emitir y consultar el estado de pólizas o siniestros.

14.4 Aplicación Mobile: reporte de siniestro y asistencia

El reporte de siniestro se inicia desde Siniestros → Reportar siniestro. En el paso de evidencias, la app permite tomar fotos y grabar videos directamente desde la cámara. La historia HU020 define un máximo de 10 evidencias y videos de hasta 30 segundos o 50 MB por archivo.
1. Abrir Evidencias y escoger Tomar foto o Grabar video.
2. Revisar la captura antes de continuar. La evidencia puede repetirse o eliminarse.
3. Confirmar que la evidencia quede asociada con fecha, hora y ubicación de captura.
4. Si no hay conexión, terminar el reporte y dejarlo guardado localmente como pendiente de sincronización.
5. Cuando vuelva la conexión, revisar que el reporte se sincronice y se muestre el número de radicado.
6. Después de reportar el siniestro, se puede solicitar asistencia en sitio, compartir la ubicación y consultar el tiempo estimado de llegada.

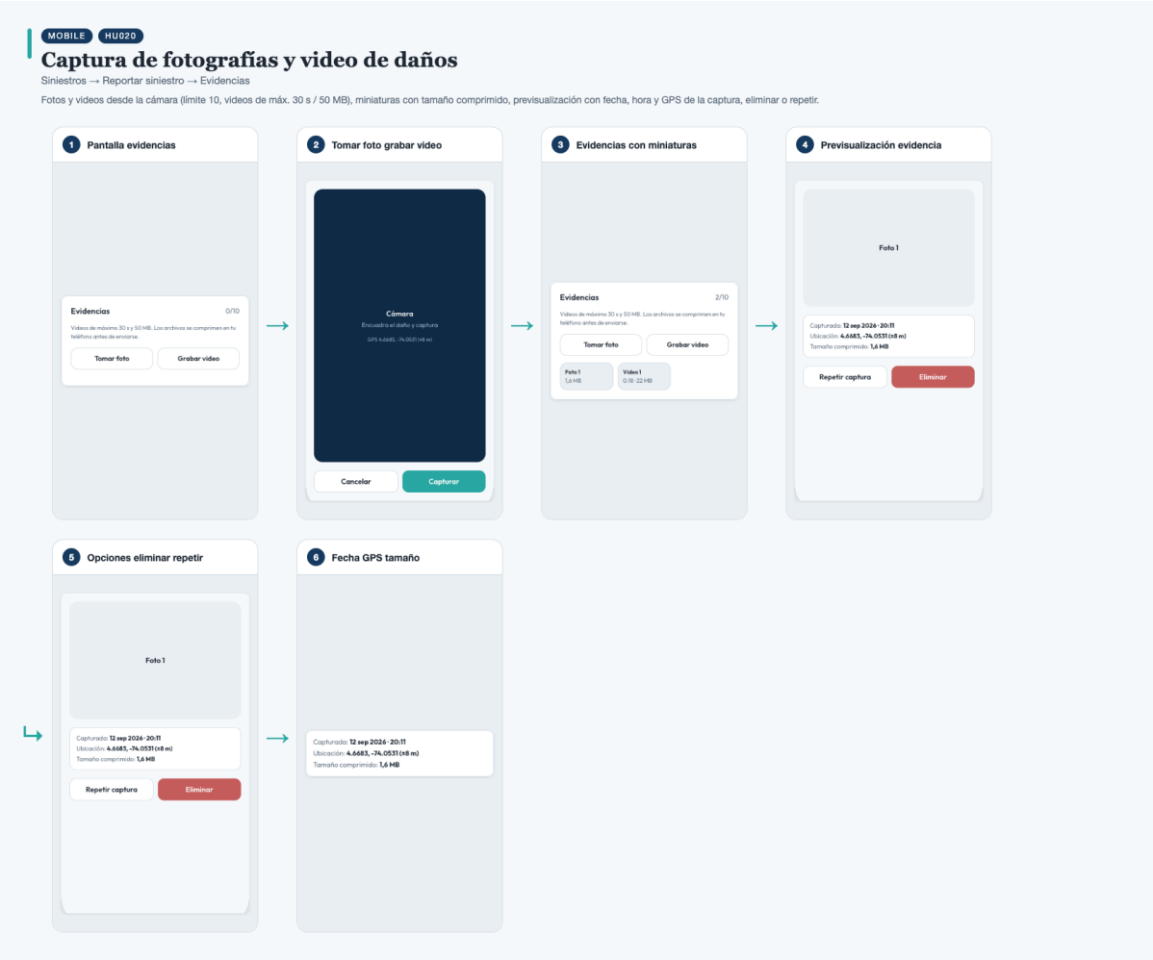


Ilustración 10. Captura de evidencias desde la aplicación Mobile (HU020).

14.5 Aplicación Mobile: compra y activación de un seguro

Para comprar un seguro, el cliente entra a Comprar seguro. La aplicación muestra únicamente los productos habilitados para venta móvil y, al escoger uno, abre el formulario correspondiente. La cotización muestra el precio y las coberturas antes de que el usuario decida pagar.

1. Seleccionar uno de los productos disponibles.
2. Diligenciar el formulario de cotización. Si falta un dato o un valor no cumple la validación, corregirlo antes de continuar.
3. Revisar la prima, las coberturas, la vigencia propuesta y la validez de la cotización.
4. Seleccionar Continuar al pago mientras la cotización siga vigente y confirmar el valor que se va a cobrar.
5. Si el pago es aprobado, esperar la emisión y revisar el número de póliza, la fecha de inicio, la fecha de fin y las coberturas.
6. Si el pago es rechazado o la emisión no termina correctamente, la aplicación no debe mostrar una póliza activa.

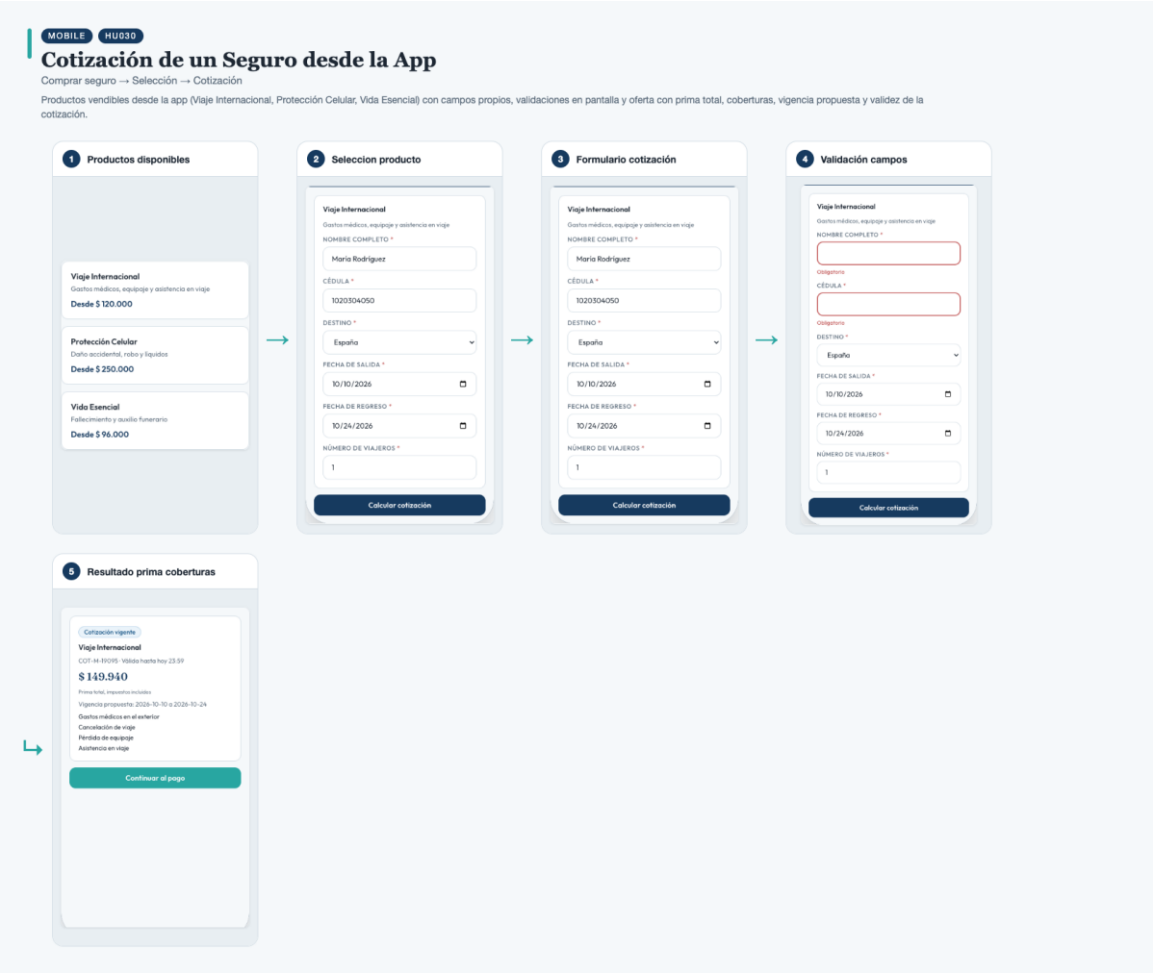


Ilustración 11. Cotización de un seguro desde la aplicación Mobile (HU030).

14.6 Aplicación Mobile: renovación de pólizas

Desde Mis pólizas, el cliente puede abrir una póliza próxima a vencer y consultar la oferta de renovación. Esta consulta es de solo lectura: ver la nueva prima, la vigencia y las coberturas propuestas no modifica la póliza que todavía está activa.

1. Entrar a Mis pólizas y abrir la póliza próxima a vencer.
2. Seleccionar Ver oferta de renovación.
3. Comparar la prima actual con la nueva, revisar la nueva vigencia y las coberturas propuestas.
4. Si se decide continuar, seleccionar Renovar ahora y confirmar el valor a pagar.
5. Si el pago es aprobado, revisar la confirmación y las nuevas fechas de vigencia. Si es rechazado, la póliza actual permanece intacta.

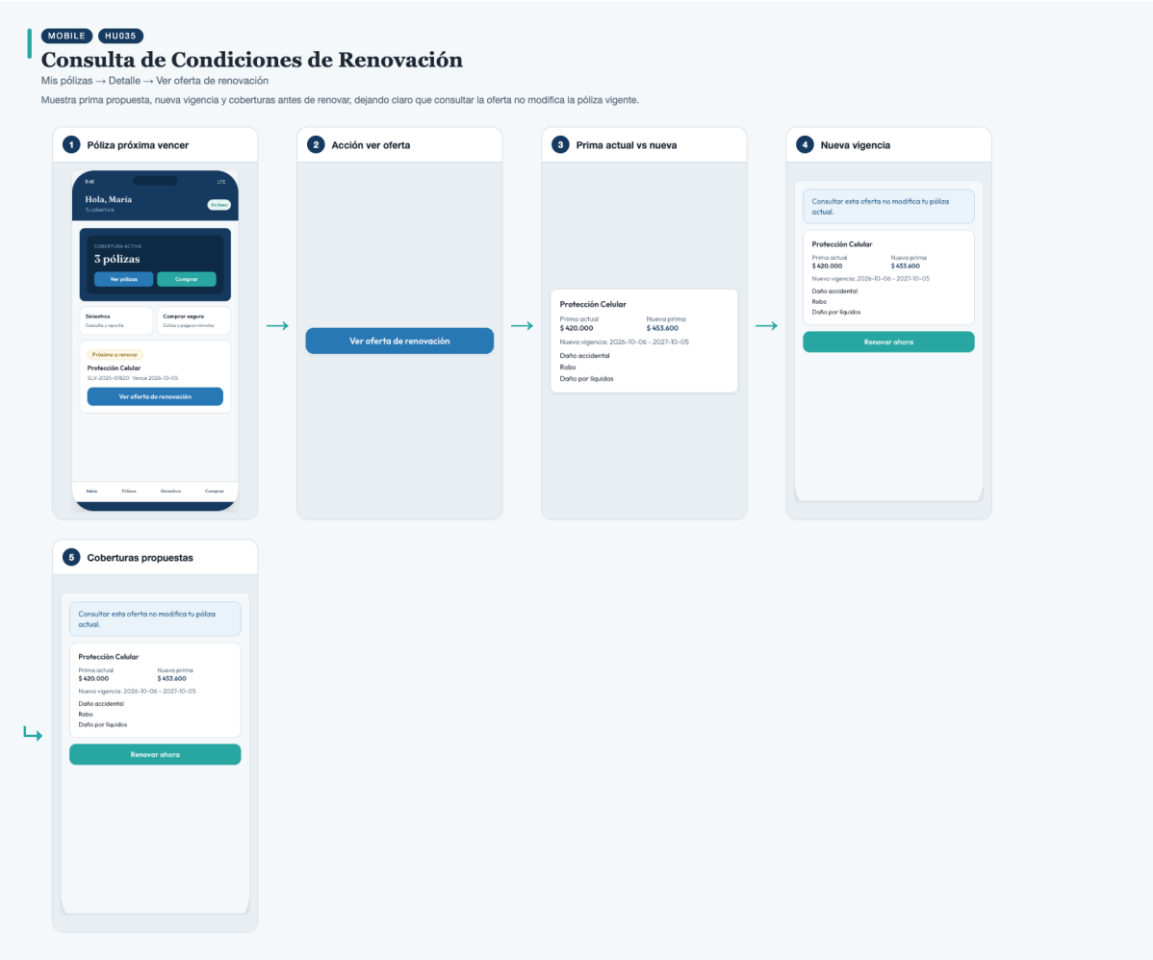


Ilustración 12. Consulta de condiciones antes de renovar una póliza (HU035).

14.7 Validaciones y estados que debe revisar el usuario

Durante los recorridos, Solventa informa el estado del proceso antes de ejecutar una acción irreversible. Los mensajes más importantes son los de campos obligatorios o inválidos, cotización vencida, pago aprobado o rechazado, póliza cancelada o vencida, reporte pendiente de sincronización, credenciales generadas y operación en modo degradado. La recomendación de uso es revisar siempre el resumen final antes de confirmar pagos, cancelaciones, endosos o aprovisionamiento de credenciales.